



RÉPUBLIQUE DU BÉNIN
MINISTÈRE DE L'ENSEIGNEMENT SUPÉRIEUR
ET DE LA RECHERCHE SCIENTIFIQUE



UNIVERSITÉ NATIONALE DES SCIENCES, TECHNOLOGIES,
INGÉNIERIE ET MATHÉMATIQUES (UNSTIM) D'ABOMEY

ÉCOLE NATIONALE SUPÉRIEURE DE GÉNIE MATHÉMATIQUE ET MODÉLISATION (ENSGMM)

N° Attribué par la bibliothèque :

--	--	--	--	--	--	--	--	--	--

MÉMOIRE DE FIN DE FORMATION POUR L'OBTENTION DU DIPLÔME D'INGÉNIEUR DE CONCEPTION

Spécialité : Mathématiques Appliquées et Modélisation

Option : Modélisation Aléatoire, Statistique et Finance (MASF)

Attribution des profits et pertes d'un portefeuille par réseaux de neurones profonds et intelligence artificielle explicable

Présenté par :
Emmanuel Massavo Abed-négo SALAKO

Sous la supervision de :
Dr (MC) Aliou MOUSSA DJIBRIL
Enseignant-Chercheur à l'UNSTIM d'Abomey
Maître de Conférences des Universités du CAMES

Sous l'encadrement de :
Dr (MA) Mintodê Nicodème ATCHADE
Statisticien Économètre
Enseignant-Chercheur à l'ENSGMM/UNSTIM d'Abomey
Maître Assistant des Universités du CAMES

Soutenu à Abomey, le 30 Octobre 2025

Composition du jury

Président : Dr (MC) Adébiyi Joseph ADECHINAN

Membres : Dr (MA) Nicodème ATCHADE
Dr (MC) Bernard TOKPOHOZIN

Année académique 2024–2025

L'Ecole Nationale Supérieure de Génie Mathématique et Modélisation (ENSGMM) n'entend donner aucune approbation aux opinions émises dans ce document. Les raisonnements et arguments reviennent donc à l'auteur.

Approbation

Nous certifions que le présent mémoire a été réalisé par l'auteur et exempt de tout plagiat. Il est arrivé à terme et peut être soutenu devant un jury.

Abomey, le

Signatures

Encadreur :

Superviseur :

**Dr Mintodê Nicodème
ATCHADE**

**Dr Aliou MOUSSA
DJIBRIL**

DEDICACE

« *Dédicace* »

À Dieu le Père , le Fils et le Saint Esprit ; à mon Cher Papa [Marcelin SALAKO](#) et à ma Chère Maman [Yvette KOUTON](#).

REMERCIEMENTS

Je rends, avant toute chose, grâce à l'Éternel Dieu Tout-Puissant pour ses innombrables bienfaits et pour la force qu'Il m'a accordée tout au long de mon parcours.

J'exprime ensuite ma profonde gratitude :

- au Recteur de l'UNSTIM, **Professeur Joachim Djimon GBENOU**, pour sa vision éclairée et son leadership ;
- à mon Superviseur, **Dr (MC) Aliou MOUSSA DJIBRIL**, Directeur de l'ENSGMM, pour son accompagnement constant, son exigence scientifique et sa grande disponibilité ;
- à mon Encadreur, **Dr (MA) Mintodê Nicodème ATCHADE**, pour son suivi rigoureux, sa patience et ses précieux conseils ;
- à l'ensemble des Autorités et Enseignants de l'ENSGMM, pour la qualité de l'enseignement et de la formation reçus ;
- au **Dr (MC) Christian AKOWANOU**, Directeur de l'INSPEI, pour son engagement et son soutien ;
- au **Directeur de la Recherche et des Études Stratégiques (DGE/DRES), Dr Jude EGGOH**, pour m'avoir accueilli lors de mon stage académique ;
- au **Dr Prince HOUSSOU**, pour ses encouragements continus et son appui indéfectible ;
- à mes camarades de la cinquième promotion de l'ENSGMM et de l'INSPEI, pour leur fraternité et leur solidarité au quotidien ;
- à mon père, **Marcelin SALAKO**, et à ma mère, **Yvette KOUTON**, pour leur amour indéfectible, leur rigueur et leur soutien tout au long de ma formation ;
- à mon frère, **Méchack SALAKO**, pour sa présence fraternelle, son soutien et son encouragement constant ;
- à tous mes amis, notamment **Léonel VODOUNNOU** et **Junior ADECHI**, pour leur amitié sincère et leur accompagnement fidèle ;
- enfin, aux membres du Jury, pour l'attention et le temps précieux consacrés à l'évaluation de ce travail.

LISTE DES ABRÉVIATIONS

AdamW	Adam optimizer with W eight decay
AMP	A utomatic M ixed P recision
ASU	A verage S equential U dating
ATM	A t T he M oney
BS	B lack- S choles (pricer)
CPU	C entral P rocessing U nit
CRR	C ox- R oss- R ubinstein (pricer binomial)
DL	D eep L earning
DTE	D ays T o E xpiry (jours à maturité)
ECDF	E mpirical C umulative D istribution F unction
FRTB	F undamental R evue of the T rading B ook
GRU	G ated R ecurrent U nit
GPU	G raphics P rocessing U nit
HPL	H ypothetical P & L (P&L hypothétique)
IA	I ntelligence A rtificielle
ICMPA	I nstitut de C haîres en P hysique M athématique et A pplications
ITM	I n T he M oney
IV	I mplicit V olatility (volatilité implicite)
KS	K olmogorov- S mirnov (statistique de test)
LSTM	L ong S hort- T erm M emory
MAE	M ean A bsolute E rror (erreur absolue moyenne)
ML	M achine L earning
MLP	M ulti L ayer P erceptron
MSE	M ean S quared E rror
OAT	O ne- A t- T ime
OTM	O ut O f T he M oney
P&L	P rofit & L oss (profits et pertes)
PLA	P & L A tribution (test FRTB)
RNN	R ecurrent N eural N etwork
RMSE	R oot M ean S quared E rror
RTPL	R isk T heoretical P & L (P&L théorique du modèle)
SHAP	S Hapley A dditive ex P lanations
SU	S equential U dating
USD	U nited S tates D ollar
XAI	e Xplainable A rtificial I ntelligence (IA explicable)
XGB	X GBoost (Extreme Gradient Boosting)
XOF	F ranc de la C ommunauté F inancière A fricaine

LISTE DES TABLEAUX

3.1	Performances prédictives des modèles sur l'année 2022.	25
3.2	Erreurs par tranche de moneyness — LSTM ($L = 6$, DRISK_core+ ρ). . .	26
3.3	Erreurs par tranche de maturité (jours) — LSTM ($L = 6$, DRISK_core+ ρ). .	27
3.4	Erreurs par quartiles de volatilité implicite — LSTM ($L = 6$, DRISK_core+ ρ).	28
3.5	Analyse des extrêmes : seuil q_{99} , erreurs et détection des pertes — LSTM ($L = 6$, DRISK_core+ ρ).	28
3.6	Ratios de complétude des attributions (sans base / avec base).	29
3.7	Mix global des contributions SHAP (somme signée 2022) et parts absolues.	29
3.8	OAT (Black–Scholes) : résidu relatif $ R^{\text{OAT}} / P_4 - P_0 $ et écart additif moyen.	32
3.9	Écart SU–ASU (pricer Black–Scholes) : MAD et RMSE par facteur. . . .	32
3.10	Écart SU–ASU (pricer CRR, contrôle d'américanité) : MAD et RMSE par facteur.	32
3.11	Comparaison XAI–ASU (pricer Black–Scholes) : corrélations, biais et régressions par facteur.	33
3.12	Corrélations mensuelles XAI–ASU (2022) par facteur : <i>min–médiane–max</i> . .	34

TABLE DES FIGURES

3.1	Séries quotidiennes : $RTPL_{ML}$ (prédit) vs HPL_{mid} (référence marché) et HPL_{pricer} (pricer).	25
3.2	Diagnostic PLA : dispersion $RTPL_{ML}$ vs HPL_{mid} (gauche); distributions cumulées (ECDF) des résidus (droite).	26
3.3	Heatmap du MAE selon la moneyness et la maturité (DTE) — LSTM ($L = 6$, DRISK_core+ ρ).	27
3.4	Somme des contributions signées par familles de facteurs ($\Delta, \nu, \theta, \rho$, autres).	30
3.5	Contributions moyennes signées par niveau de moneyness (OTM/ATM/ITM).	30
3.6	Contributions quotidiennes empilées et séries de référence ($RTPL_{ML}$, HPL_{mid}).	31
3.7	Histogrammes des résidus : $HPL_{mid} - RTPL_{ML}$ (gauche) et $HPL_{mid} - pnl_{pricer}$ (droite).	33
3.8	Comparaison XAI vs ASU-BS — contributions journalières empilées (janvier 2022). Les deux approches suivent la dynamique de HPL_{mid} avec de faibles écarts d'échelle.	34
3.9	Comparaison XAI vs ASU-BS — contributions journalières empilées (février 2022). En régime volatil, les deux méthodes sous-estiment l'amplitude des variations.	35

RÉSUMÉ

Ce mémoire propose une approche d'attribution du *Profit and Loss* (P&L) fondée sur la combinaison de l'apprentissage profond et de l'intelligence artificielle explicable (XAI), dans le cadre réglementaire du *Fundamental Review of the Trading Book* (FRTB). L'objectif est d'expliquer de manière transparente les variations du *Risk Theoretical P&L* (RTPL) d'un portefeuille d'options américaines sur l'action NVIDIA (NVDA). Le modèle développé repose sur un réseau de neurones récurrent LSTM (Long Short-Term Memory, $L = 6$) entraîné sur une famille de variables de risque *DRISK_core+*, puis expliqué à l'aide de la méthode SHAP (*SHapley Additive exPlanations*). Cette combinaison permet d'attribuer chaque prédiction du P&L aux principaux facteurs de risque $(\Delta, \nu, \theta, \rho)$ de façon cohérente et interprétable. Les attributions XAI ont ensuite été comparées aux décompositions analytiques OAT, SU et ASU implémentées sous le modèle de Black–Scholes. Les résultats montrent une forte corrélation entre les facteurs directionnels de l'approche explicable et ceux issus des méthodes analytiques, attestant de la robustesse et de la cohérence du modèle. L'approche proposée concilie ainsi performance prédictive, interprétabilité financière et conformité réglementaire, offrant un cadre fiable pour la gestion et la validation des risques de marché.

Mots clés : Attribution de profit et perte ; Apprentissage profond ; Réseaux de neurones récurrents ; Intelligence artificielle explicable ; Valeurs de Shapley ; FRTB ; Risque de marché.

ABSTRACT

This thesis presents an attribution approach for the *Profit and Loss* (P&L) of a financial portfolio, based on deep learning and explainable artificial intelligence (XAI), within the regulatory framework of the *Fundamental Review of the Trading Book* (FRTB). The objective is to provide a transparent explanation of the variations in the *Risk Theoretical P&L* (RTPL) for a portfolio of American call options on the NVIDIA (NVDA) stock. The proposed model relies on a recurrent neural network (LSTM, Long Short-Term Memory, $L = 6$), trained on a family of risk-weighted variables (*DRISK_core+*), and interpreted using the SHAP (*SHapley Additive Explanations*) method. This combination allows each P&L prediction to be decomposed into coherent and interpretable contributions from the main risk factors $(\Delta, \nu, \theta, \rho)$. The explainable attributions were then compared with analytical decompositions (OAT, SU, ASU) implemented under the Black–Scholes model. The results show a strong correlation between the directional factors obtained from the explainable approach and those derived from analytical methods, confirming the robustness and economic consistency of the model. This approach thus reconciles predictive performance, financial interpretability, and regulatory compliance, providing a reliable framework for risk management and model validation.

Keywords : P&L Attribution; Deep Learning; Recurrent Neural Networks; Explainable AI; Shapley Values; FRTB; Market Risk.

Table des matières

DEDICACE	iii
Remerciements	iv
Résumé	viii
Résumé	ix
Introduction Générale	1
1 Cadre conceptuel et théorique	4
1.1 Introduction	4
1.2 Clarification conceptuelle	4
1.3 Revue de littérature	8
2 Cadre méthodologique	11
2.1 Introduction	11
2.2 Matériels utilisés	11
2.3 Méthodes	13
3 Résultats et Discussion	24
3.1 Introduction	24
3.2 Résultats de la modélisation prédictive du P&L	24
3.3 Analyse des erreurs et diagnostic de robustesse	26
3.4 Attribution explicable du P&L (méthode SHAP)	28
3.5 Comparaison XAI et attributions analytiques	31
3.6 Discussion des résultats	36
Conclusion	37
Conclusion générale	38

INTRODUCTION GÉNÉRALE

1. Contexte et justification de l'étude

En finance, l'explication des profits et pertes (*Profit and Loss*, P&L) constitue un enjeu central pour la gestion des risques, la mesure de la performance et la transparence réglementaire. Depuis la *Revue Fondamentale du Portefeuille de Négociation* (*Fundamental Review of the Trading Book*, FRTB) issue de *Bâle III*, le *P&L Attribution Test* (PLA) s'impose comme un outil de référence pour évaluer la cohérence entre les modèles internes de risque et les profits et pertes effectivement observés sur le marché.

Les approches analytiques classiques d'attribution du P&L telles que le *One-at-a-Time* (OAT), le *Sequential Updating* (SU), l'*Average Sequential Updating* (ASU) et l'*Infinitesimal Averaged Sequential Updating* (IASU) assurent une base théorique rigoureuse et une traçabilité claire, mais peinent à tenir compte du chemin complet des instruments financiers, nécessitent une fonction de valorisation explicite respectant des conditions de régularité (comme dans le cas de l'IASU), et deviennent coûteuses en calcul pour des portefeuilles complexes [1, 2].

Parallèlement, les avancées récentes en *apprentissage profond* (*Deep Learning*) ont profondément transformé la modélisation financière. Les réseaux neuronaux récurrents, tels que les *Long Short-Term Memory* (LSTM) et *Gated Recurrent Unit* (GRU), peuvent approximer des fonctions complexes, gérer un grand nombre de variables explicatives et capturer les dépendances temporelles propres aux séries de marché [3, 4]. Cependant, ces modèles sont souvent qualifiés de « *boîtes noires* » : bien qu'efficaces pour la prédiction, leurs décisions internes demeurent difficiles à interpréter, ce qui limite leur adoption dans les environnements réglementés [5, 6].

C'est dans ce cadre que s'inscrit la présente étude, qui vise à déployer un modèle de réseau de neurones profonds explicable (*Explainable Artificial Intelligence*, XAI) pour attribuer, de manière cohérente et interprétable, les profits et pertes d'un portefeuille d'options américaines sur NVIDIA.

2. Problématique et question de recherche

L'intérêt de cette recherche réside dans la nécessité de dépasser le compromis entre la performance prédictive et l'interprétabilité des modèles d'attribution du *Profit and Loss* (P&L). Les méthodes analytiques classiques assurent une transparence totale mais demeurent limitées lorsqu'elles sont appliquées à des portefeuilles d'instruments financiers complexes avec des facteurs de risques à effets non linéaires et interactions croisées. À l'inverse, les réseaux de neurones profonds offrent une forte capacité de modélisation, mais leur opacité rend difficile leur utilisation dans un cadre réglementé comme celui du *Fundamental Review of the Trading Book* (FRTB).

Nous postulons qu'une approche hybride, combinant la puissance des modèles de *Deep Learning* et la clarté des méthodes d'*Intelligence Artificielle Explicable* (XAI), permettra d'attribuer le P&L de manière à la fois précise, stable et interprétable. Une telle approche offrirait aux institutions financières un outil fiable pour la validation de leurs modèles internes et l'analyse des risques de marché.

Comment combiner les réseaux de neurones profonds et l'intelligence artificielle explicable pour attribuer les profits et pertes d'un portefeuille financier ?

3. Objectifs du mémoire

Objectif général

L'objectif général de ce mémoire est de déployer une méthode hybride pour expliquer les profits et pertes d'un portefeuille.

Objectifs spécifiques

1. Construire un modèle prédictif du P&L journalier conforme au *P&L Attribution Test* à l'aide de réseaux de neurones récurrents (LSTM et GRU).
2. Évaluer la fiabilité de la méthode SHAP dans l'explication des prédictions du modèle.
3. Comparer les attributions générées par l'approche réseau de neurones profonds et IA explicable avec celles des méthodes classiques (OAT, SU, ASU).

4. Limites de l'étude

Cette étude repose sur l'analyse d'un portefeuille d'options américaines sur l'actif NVIDIA, construit à partir de données de marché réelles, retraitées et alignées sur le calendrier du NYSE. Les résultats concernent donc un univers unique et homogène d'options *call*, sans extension multi-actifs ni prise en compte des corrélations inter-portefeuilles. Certaines dimensions réglementaires, telles que le *backtesting* (tests rétrospectifs de performance) complet n'ont pas été explorées. Enfin, la complexité des architectures neuronales a été limitée par les ressources de calcul disponibles et par la taille du sous-échantillon retenu pour l'analyse explicable.

5. Résultats attendus et cibles

L'étude devrait montrer qu'un modèle neuronal profond peut reproduire fidèlement le P&L journalier tout en satisfaisant le *P&L Attribution Test*. Il est également attendu que la méthode SHAP offre une décomposition stable et économiquement cohérente des prédictions du modèle. Enfin, la comparaison avec les approches analytiques classiques (OAT, SU, ASU) devrait confirmer la capacité de l'approche explicable à fournir des attributions plus robustes et conformes au cadre réglementaire.

6. Nouveauté de l'étude

La présente étude se distingue par la mise en place d'un cadre d'attribution du *Profit and Loss* (P&L) combinant apprentissage profond et intelligence artificielle explicable, dans un environnement conforme aux exigences de la Revue Fondamentale du Portefeuille de Trading. Alors que la plupart des travaux existants sur l'attribution des gains et pertes recourent à des méthodes peu efficaces pour capturer la dynamique complexe des marchés, très peu exploitent la puissance de l'intelligence artificielle explicable dans un cadre réglementaire.

Cette recherche propose ainsi une approche hybride comparant la modélisation neuronale séquentielle aux méthodes analytiques classiques d'attribution (OAT, SU, ASU), dans une perspective de transparence, d'explicabilité et de conformité aux standards de validation des modèles de risque.

7. Divisions du mémoire

Ce mémoire s'articule autour de trois chapitres principaux :

- Chapitre 1 : Cadre conceptuel et théorique. Il présente les fondements conceptuels, les méthodes d'attribution existantes et les principaux travaux antérieurs relatifs à l'explicabilité des modèles de P&L.
- Chapitre 2 : Matériels et méthodes. Il décrit les données utilisées, les environnements de calcul, les modèles expérimentés (OAT, SU, ASU, LSTM, GRU) et la méthodologie d'intégration du cadre SHAP.
- Chapitre 3 : Résultats et discussion. Il analyse et compare les résultats obtenus pour évaluer la performance et la cohérence des différentes approches d'attribution du P&L.

Enfin, une conclusion générale synthétise les principaux résultats obtenus et ouvre des perspectives pour des travaux futurs.

CADRE CONCEPTUEL ET THÉORIQUE

1.1 Introduction

Cette section présente les notions fondamentales nécessaires à la compréhension de notre étude. Elle introduit les concepts clés liés au profit et perte (P&L), à son attribution et aux principaux cadres conceptuels qui interviennent dans la modélisation financière.

1.2 Clarification conceptuelle

1.2.1 Le Profit et Perte (P&L)

Le profit et perte (*Profit and Loss*) représente la variation de la valeur d'un portefeuille financier entre deux dates successives. Il mesure le gain ou la perte enregistrée sur une période donnée et constitue un indicateur central de performance et de gestion du risque. D'un point de vue formel, le P&L s'écrit :

$$P\&L_t = V_t - V_{t-1}, \quad (1.1)$$

où V_t désigne la valeur du portefeuille à la date t .

1.2.2 L'attribution du P&L

L'attribution du P&L consiste à décomposer la variation totale de la valeur d'un portefeuille en contributions associées à chacun des facteurs de risque sous-jacents. Elle permet d'identifier les origines des gains et pertes, d'évaluer la qualité du modèle de risque et de vérifier la cohérence économique de la valorisation. Sa formulation générale s'écrit :

$$P\&L_t = \sum_{i=1}^n \Delta P\&L_{i,t} + \varepsilon_t, \quad (1.2)$$

où $\Delta P\&L_{i,t}$ désigne la contribution du facteur i et ε_t le terme résiduel inexpliqué.

Une bonne attribution vise à minimiser ce résidu ε_t , de sorte que la somme des contributions explique presque intégralement la variation observée du P&L. La qualité de cette décomposition détermine la fiabilité du modèle et sa conformité réglementaire dans le cadre du FRTB.

Espaces d'attribution. Deux cadres d'analyse coexistent :

- **Greek-space** : décomposition fondée sur les sensibilités $(\Delta, \Gamma, \nu, \Theta, \rho)$, reliant directement le P&L aux dérivées premières et secondes du modèle de prix ;
- **Variable-space** : décomposition fondée sur les chocs observés des variables d'état (S, σ, r, t) , appliquant des revalorisations successives pour mesurer l'impact exact de chaque facteur.

L'approche *Greek-space* repose sur des approximations locales via les dérivées du modèle, tandis que l'approche *Variable-space* mesure l'effet exact des variations de marché en revalorisant directement les instruments.

1.2.3 Facteurs de risque et sensibilités (Greeks)

Les facteurs de risque regroupent les variables de marché susceptibles d'affecter la valeur d'un portefeuille : le prix du sous-jacent, la volatilité implicite, le taux sans risque et le temps à maturité. Les sensibilités ou *Greeks* traduisent la variation marginale de la valeur du portefeuille face à une modification infinitésimale de ces variables.

Principaux Greeks.

$$\Delta = \frac{\partial V}{\partial S} : \text{sensibilité au prix du sous-jacent (exposition directionnelle),} \quad (1.3)$$

$$\Gamma = \frac{\partial^2 V}{\partial S^2} : \text{convexité (variation marginale de } \Delta), \quad (1.4)$$

$$\nu = \frac{\partial V}{\partial \sigma} : \text{sensibilité à la volatilité implicite (Vega),} \quad (1.5)$$

$$\Theta = \frac{\partial V}{\partial t} : \text{effet du temps (time decay, souvent négatif pour les options),} \quad (1.6)$$

$$\rho = \frac{\partial V}{\partial r} : \text{sensibilité au taux sans risque.} \quad (1.7)$$

Logique des chocs pondérés. Pour relier directement les sensibilités et les chocs de marché, on définit les termes dérivés de risque :

$$d_\Delta = \Delta_{t-1} \cdot \Delta S_t \quad (\text{impact du mouvement du sous-jacent}),$$

$$d_\nu = \nu_{t-1} \cdot \Delta IV_t \quad (\text{impact de la variation de la volatilité}),$$

$$d_\Theta = \Theta_{t-1} \cdot \Delta t \quad (\text{impact du passage du temps}),$$

$$d_\rho = \rho_{t-1} \cdot \Delta r_t \quad (\text{impact du changement du taux d'intérêt}).$$

Ces variables, appelées *chocs pondérés*, représentent les contributions élémentaires de chaque facteur au P&L total.

1.2.4 Cadre réglementaire : FRTB et P&L Attribution Test

Le *Fundamental Review of the Trading Book* (FRTB), instauré par le *Comité de Bâle sur le Contrôle Bancaire* (*Basel Committee on Banking Supervision*, BCBS), redéfinit les standards internationaux de mesure du risque de marché BASEL COMMITTEE ON BANKING SUPERVISION [7]. L'un de ses piliers est le P&L Attribution Test (PLA), dont l'objectif est de vérifier la cohérence entre les variations de valeur simulées par les modèles internes et celles observées sur le marché.

Le test vise à s'assurer que le modèle de risque reproduit fidèlement la dynamique du marché. Pour cela, il compare deux séries de profits et pertes :

- le **Risk Theoretical P&L** ($RTPL_t$) — calculé à partir du modèle interne de risque et des sensibilités du portefeuille;
- le **Hypothetical P&L** (HPL_t) — mesuré à partir des prix observés, pour un portefeuille tenu constant, calculé à partir des prix de marché ou de modèles de valorisation cohérents.

Critères statistiques. La validation repose sur deux indicateurs complémentaires :

$$\rho(RTPL_t, HPL_t) \geq \rho_{\min} \quad \text{et} \quad KS(RTPL_t, HPL_t) \leq KS_{\max}, \quad (1.8)$$

où ρ est la corrélation (Pearson ou Spearman) entre les séries, et KS la statistique du test de Kolmogorov–Smirnov mesurant l'écart entre leurs distributions. La corrélation (de Pearson) est définie par :

$$\rho(RTPL, HPL) = \frac{\text{Cov}(RTPL, HPL)}{\sigma_{RTPL} \sigma_{HPL}}, \quad (1.9)$$

où $\text{Cov}(\cdot)$ désigne la covariance et σ les écarts-types respectifs.

La statistique du test de Kolmogorov–Smirnov s'écrit :

$$KS(RTPL, HPL) = \sup_x |F_{RTPL}(x) - F_{HPL}(x)|, \quad (1.10)$$

où F_{RTPL} et F_{HPL} sont les fonctions de répartition empiriques des deux séries.

Un modèle est jugé cohérent lorsque la corrélation est élevée et que la distance KS reste faible, traduisant une similarité de forme entre les distributions.

Trois zones ont été définies selon les seuils de performance :

Zone	ρ	KS	Interprétation
Verte	0.8	0.08	Modèle conforme, utilisation autorisée pour le calcul du capital interne.
Ambre	0.7–0.8	0.08–0.12	Surveillance accrue, corrections à apporter.
Rouge	0.7	0.12	Échec du test, désactivation du modèle interne.

1.2.5 Apprentissage profond et intelligence artificielle explicable (XAI)

L'**apprentissage profond** (*Deep Learning*) désigne un ensemble de techniques issues des réseaux de neurones artificiels capables d'apprendre, à partir des données, des relations complexes et non linéaires entre variables. Un réseau de neurones profond se compose de plusieurs couches successives de transformations non linéaires :

$$h^{(l)} = \sigma(W^{(l)}h^{(l-1)} + b^{(l)}), \quad l = 1, \dots, L, \quad (1.11)$$

où $W^{(l)}$ et $b^{(l)}$ représentent respectivement les poids et biais de la couche l , et $\sigma(\cdot)$ une fonction d'activation. Cette structure permet d'extraire progressivement des représentations de plus haut niveau à partir des données brutes.

Modèles séquentiels. Pour des données temporelles comme le P&L journalier, les réseaux de neurones récurrents (*Recurrent Neural Networks*, RNN) et leurs variantes — *Long Short-Term Memory* (LSTM) et *Gated Recurrent Unit* (GRU) — sont particulièrement adaptés. Ils intègrent une mémoire interne qui capture la dépendance entre les observations passées et présentes :

$$h_t = f(Wx_t + Uh_{t-1} + b), \quad (1.12)$$

où x_t est l'entrée au temps t , h_t l'état caché et $f(\cdot)$ une fonction non linéaire.

Intelligence artificielle explicable (XAI). L'intelligence artificielle explicable (*Explainable Artificial Intelligence*, XAI) regroupe les méthodes qui rendent les modèles prédictifs interprétables. La méthode SHAP (*SHapley Additive exPlanations*) en est une approche de référence. Basée sur la théorie des jeux coopératifs, elle attribue à chaque variable x_i une contribution marginale $\phi_i(x)$ à la prédiction totale :

$$f(x) = \phi_0 + \sum_{i=1}^n \phi_i(x), \quad (1.13)$$

où ϕ_0 est la valeur moyenne du modèle. Chaque $\phi_i(x)$ représente la part du facteur x_i dans la décision du modèle, selon trois principes fondamentaux : *efficacité* (la somme reconstitue la prédiction), *symétrie* (les variables équivalentes sont traitées de manière identique) et *additivité* (la décomposition est stable).

1.3 Revue de littérature

1.3.1 Méthodes analytiques d'attribution du P&L

Les approches analytiques d'attribution s'articulent classiquement autour des schémas *One-at-a-Time* (OAT), *Sequential Updating* (SU) et *Average Sequential Updating* (ASU). Elles diffèrent par la manière d'introduire les variations des facteurs de risque dans le calcul des contributions au P&L [1, 2].

OAT (One-at-a-Time). Un seul facteur varie à la fois, les autres étant maintenus constants :

$$\Delta P\&L_i = f(X_{1,t-1}, \dots, X_{i,t}, \dots, X_{n,t-1}) - f(X_{1,t-1}, \dots, X_{i,t-1}, \dots, X_{n,t-1}).$$

La méthode est simple et indépendante d'un ordre d'actualisation, mais elle ignore les effets croisés et peut laisser un résidu explicatif non nul [1, 2].

SU (Sequential Updating). Les facteurs sont mis à jour séquentiellement selon un ordre prédéfini :

$$\Delta P\&L_i = f(X_{1,t}, \dots, X_{i,t}, X_{i+1,t-1}, \dots) - f(X_{1,t}, \dots, X_{i-1,t}, X_{i,t-1}, \dots).$$

La somme des contributions est exacte, mais la décomposition dépend de l'ordre retenu, ce qui motive des approches symétriques [1].

ASU (Average Sequential Updating). Pour supprimer la dépendance à l'ordre, l'ASU moyenne les contributions sur toutes les permutations des facteurs :

$$\Delta P\&L_i^{ASU} = \frac{1}{n!} \sum_{\pi \in \Pi_n} \left[f(X_{\pi(1),t}, \dots, X_{\pi(i),t}, X_{\pi(i+1),t-1}, \dots) - f(X_{\pi(1),t}, \dots, X_{\pi(i-1),t}, X_{\pi(i),t-1}, \dots) \right].$$

Cela assure symétrie et exactitude, au prix d'un coût combinatoire plus élevé [2].

Cadre en temps continu et ISU/IASU. Lorsque les facteurs de risque évoluent de façon continue, la limite d'une SU raffinée conduit à une *décomposition infinitésimale* (ISU), et la moyenne infinitésimale (IASU) satisfait simultanément exactitude, symétrie et normalisation. Une ASU suffisamment fine ou la moyenne de deux SU opposées (2SU) peut approcher efficacement l'IASU tout en réduisant le coût de calcul [2, 8, 9].

Cadre réglementaire et mise en œuvre PLA. Dans le FRTB, le *P&L Attribution Test* compare le *Hypothetical P&L* (HPL) au *Risk-Theoretical P&L* (RTPL) au niveau du desk. Les retours d'expérience soulignent l'importance de la qualité des données, de l'alignement entre sensibilités (*Greeks*) et chocs, ainsi que de la granularité temporelle, qui influent sur la robustesse des décompositions OAT/SU/ASU et sur la lecture réglementaire des résultats [10, 11].

Liens avec l'allocation de capital et l'attribution factorielle. L'attribution du P&L se relie à la question de l'allocation du capital pour des mesures de risque cohérentes (par ex. ES), avec des estimateurs et procédures de backtesting proposés par BIELECKI et al. [12]. Des travaux comme ceux de FREI [13] et MAI [14] élargissent le cadre à des analyses de risque par composantes macroéconomiques (taux, change, *carry*, résiduel), utiles à l'interprétation empirique du P&L dans une perspective de gestion intégrée des risques.

1.3.2 Apports de l'intelligence artificielle et de l'explicabilité

Les réseaux de neurones profonds permettent de capturer des relations non linéaires et des dépendances complexes au sein des séries financières. BÜHLER et al. [4] introduisent le concept de *Deep Hedging*, où un réseau apprend une stratégie de couverture optimale sous coûts de transaction. ROSSI, COCCO et BORMETTI [3] utilisent également des réseaux neuronaux pour approximer la distribution du P&L de portefeuilles dérivés. D'autres travaux confirment la pertinence de modèles séquentiels pour la prévision de prix et de risques : PIMENTEL, ALEXANDRE et SEBASTIÃO [15] appliquent un LSTM à des options S&P 500 avec validation séquentielle, et LIU, JIN et ZHANG [16] montrent l'intérêt d'inclure la *realized skewness* comme variable d'entrée. Dans une approche axée sur la couverture, CHEN et LI [17] apprennent directement des ratios de couverture pour des options d'indice, tandis que FATOUROS, PLIAKOS et al. [18] proposent un cadre *DeepVAR* pour estimer le risque de portefeuille (VaR/ES). Enfin, BASCHETTI, DE MARCO et MICHELETTI [19] développent une calibration *deep* de modèles de volatilité via des grilles aléatoires, améliorant la robustesse des paramètres utilisés dans les calculs de P&L.

Des modèles hybrides combinent désormais approches analytiques et réseaux neuronaux. QIAO et WAN [20] montrent qu'un réseau peut apprendre un correctif sur la couverture Δ -Black-Scholes pour réduire les erreurs résiduelles, tandis que LOKESHWAR et JAIN [21] étudient des stratégies de couverture statique interprétables avec une analyse du P&L par instrument. Ces travaux ouvrent la voie à une articulation entre contributions analytiques (OAT/SU/ASU, ISU/IASU) et explications issues de modèles d'apprentissage.

IA explicable (XAI) pour la finance et le risque. Pour concilier performance prédictive et transparence, les approches d'*intelligence artificielle explicable* se développent. LUNDBERG et LEE [5] posent le cadre des valeurs de Shapley appliquées à la prédiction (méthode SHAP), fondé sur la théorie des jeux de SHAPLEY [22]. AAS, JULLUM et LØLAND [23] en proposent une extension traitant la dépendance entre variables. En finance, MOEHLE, BOYD et ANG [6] appliquent les valeurs de Shapley à la mesure de performance de portefeuilles, et BELL, DEVANATHAN et BOYD [24] proposent des algorithmes efficaces pour leur calcul dans un contexte de régression. SHEN [25] illustrent l'usage de SHAP pour interpréter un modèle GRU avec auto-attention appliqué à la tarification d'options américaines.

Au-delà de SHAP, les revues de littérature de CERNEVIČIENĖ et COAUTHORS [26] et KHAN et COAUTHORS [27] synthétisent l'usage des principales techniques explicables (PDP, LIME, SHAP, IG, ALE) dans le domaine financier. FRITZ-MORGENTHAL, WEYDE et al. [28] discutent leur intégration dans les pratiques de validation et de gouvernance des modèles, tandis que le rapport du CFA INSTITUTE RESEARCH AND

POLICY CENTER [29] présente une vision institutionnelle des exigences d’auditabilité et de traçabilité. Des extensions structurelles telles que *GrammarSHAP* [30] illustrent la généralisation des méthodes d’attribution à des modèles plus complexes.

Les travaux théoriques récents [2, 8, 9] offrent un cadre rigoureux reliant les méthodes analytiques (OAT, SU, ASU, ISU/IASU) aux approches explicables issues du *machine learning*. En pratique, des schémas simplifiés (ASU fine, 2SU) permettent d’approcher les décompositions continues tout en limitant le coût calculatoire.

Conclusion

Ce chapitre a présenté les notions fondamentales et les principaux travaux relatifs à l’attribution du P&L. Les limites des approches analytiques classiques et les apports récents de l’apprentissage profond justifient l’adoption d’un cadre hybride conciliant performance et explicabilité. Le chapitre suivant décrit la méthodologie développée pour mettre en œuvre et évaluer cette approche.

CADRE MÉTHODOLOGIQUE

2.1 Introduction

Ce chapitre présente les données, outils et démarches méthodologiques utilisés dans le cadre de cette étude. L'objectif est de décrire le processus complet de construction, d'entraînement et d'évaluation des modèles appliqués à l'attribution du profit et perte (P&L). La méthodologie repose sur la mise en place d'un cadre de référence pour le P&L, la conception de modèles neuronaux séquentiels (LSTM et GRU), l'application de la méthode d'explicabilité SHAP et la comparaison des résultats avec les méthodes analytiques classiques (OAT, SU et ASU). Les sections suivantes détaillent successivement les matériels, la description du jeu de données, les langages et logiciels employés, ainsi que les principales étapes méthodologiques.

2.2 Matériels utilisés

Jeux de données

L'étude s'appuie sur les chaînes d'options américaines publiées par la *Chicago Board Options Exchange* (CBOE), disponibles via la plateforme *CBOE DataShop*¹. Ces données, couvrant l'actif **NVIDIA (NVDA)** sur la période du premier trimestre 2020 au quatrième trimestre 2022, regroupent les cotations historiques de fin de journée pour l'ensemble des options cotées. Une version prétraitée de ce jeu de données, intitulée *NVDA Option Chains – Q1 2020 to Q4 2022*, est également accessible en libre accès sur la plateforme *Kaggle*².

L'analyse se concentre sur les options de type *call*, afin d'assurer la cohérence méthodologique et de faciliter l'interprétation des signaux de profit et perte (P&L).

Les principales variables exploitées sont :

- le prix du sous-jacent S_t , exprimé en dollars américains (USD);

1. <https://datashop.cboe.com/>

2. <https://www.kaggle.com/datasets/kylegraupe/nvda-daily-option-chains-q1-2020-to-q4-2022>

- le prix d'exercice (*strike*) K , exprimé en dollars américains (USD);
- la volatilité implicite IV_t , exprimée en pourcentage annuel (%);
- le temps à maturité DTE_t , exprimé en jours calendaires;
- le taux sans risque r_t , exprimé en taux annuel décimal (par exemple 0,02 pour 2%);
- la moneyness (S_t/K) , grandeur sans unité représentant le rapport entre le prix du sous-jacent et le prix d'exercice.

Avant exploitation, les données ont fait l'objet d'un prétraitement comprenant les étapes suivantes :

- (i) **Contrôle d'arbitrage.** Application des bornes théoriques $\max(0, S_t - K) \leq P_t \leq S_t$, afin d'écarter toute violation élémentaire (valeur intrinsèque et borne supérieure par le sous-jacent). Toute observation ne respectant pas cette inégalité a été retirée.
- (ii) **Filtrage des valeurs aberrantes.** Suppression des enregistrements incohérents (cotations discontinues, écarts extrêmes, maturités nulles) pour éviter les distorsions statistiques.
- (iii) **Encadrement de la volatilité implicite.** Bornage des valeurs extrêmes d' IV_t à l'intervalle $[0.005, 5.0]$ de façon à limiter l'influence d'un faible nombre d'observations instables.
- (iv) **Construction des taux sans risque.** Obtention de r_t par interpolation journalière d'une courbe issue des séries publiques *Federal Reserve Economic Data (FRED)*³, puis alignement sur le calendrier du NYSE.
- (v) **Calcul du P&L quotidien.** Définition du prix moyen bid-ask $P_t^{\text{moy}} = \frac{1}{2}(P_t^{\text{bid}} + P_t^{\text{ask}})$ et construction du P&L hypothétique à partir des mid-prices :

$$HPL_{\text{mid},t} = P_t^{\text{moy}} - P_{t-1}^{\text{moy}}.$$

Après filtrage et alignement sur le calendrier de la Bourse de New York(NYSE), le jeu de données final comprend environ 977 000 observations d'options call. L'ensemble a été nettoyé et restructuré afin d'assurer la cohérence temporelle et la fiabilité statistique des résultats.

Langages de programmation et logiciels utilisés

L'ensemble des traitements a été réalisé sous **Python 3.10**. Ce langage a été retenu pour sa flexibilité, la richesse de ses bibliothèques et sa large adoption scientifique.

Les principales bibliothèques utilisées sont :

- NumPy et Pandas pour la manipulation et le prétraitement des données;
- PyTorch pour l'implémentation et l'entraînement des modèles neuronaux LSTM et GRU;
- XGBoost pour le modèle de référence basé sur les arbres de décision;
- SHAP pour le calcul des contributions explicables;
- Matplotlib et Seaborn pour la visualisation;
- SymPy pour les dérivations symboliques dans les méthodes analytiques;
- Scikit-learn pour les métriques de performance et la gestion des jeux d'entraînement et de test.

3. <https://fred.stlouisfed.org/>

Les calculs ont été effectués dans l’environnement **Google Colab**, avec accélération GPU (**NVIDIA A100**) et mémoire vive de 167 Go pour l’entraînement des modèles récurrents. La rédaction du mémoire a été réalisée sous $\text{\LaTeX}$ via Overleaf.

2.3 Méthodes

2.3.1 Préparation des jeux et découpes temporelles

Les données (section § 2.1 *Matériels*) sont ordonnées par date et par identifiant de contrat, puis découpées de manière chronologique afin d’éviter toute fuite d’information. La partition retenue est la suivante :

- **Entraînement (train)** : du 2020-01-03 au 2021-06-30 ;
- **Validation (val)** : du 2021-07-01 au 2021-12-31 ;
- **Test (test)** : du 2022-01-03 au 2022-12-30.

Les variables continues sont standardisées à partir des statistiques du seul ensemble d’entraînement (moyenne et écart-type) puis transformées à l’identique sur validation et test (*anti-leakage*). Les séries sont enfin alignées sur le calendrier NYSE (jours de bourse uniquement) et synchronisées par contrat afin de garantir la disponibilité des états $t - 1$ et t nécessaires à la construction des chocs et des cibles (cf. § 2.2).

Un journal de préparation (tailles par split, nombre de séquences valides par L , taux d’exclusion après filtrages) est conservé pour la reproductibilité.

2.3.2 Construction des variables et des séquences

Soit un portefeuille d’options américaines indexé sur le sous-jacent S_t . Pour chaque contrat d’option identifié par son prix d’exercice K et son temps à maturité résiduel $\tau_t = DTE_t/252$, on note P_t le prix moyen bid-ask de clôture au jour t et

$$P\&L_t = P_t - P_{t-1}.$$

Les observations journalières sont organisées sous forme de séquences temporelles glissantes $\mathcal{S}_t = \{x_{t-L+1}, \dots, x_t\}$ de longueur $L \in \{4, 6, 8\}$, où chaque vecteur d’état $x_t \in \mathbb{R}^p$ regroupe les variables explicatives au jour t .

Variables de base. On distingue deux familles :

- (i) les variables de marché au jour t :

$$x_t^{(\text{mkt})} = (S_t, IV_t, DTE_t, r_t, M_t, \Delta S_t, \Delta IV_t),$$

où $M_t = S_t/K$ est la moneyness et $\Delta S_t = \log(S_t/S_{t-1})$, $\Delta IV_t = IV_t - IV_{t-1}$ représentent les chocs observés sur le sous-jacent et la volatilité implicite ;

- (ii) les sensibilités (Greeks) calculées à la veille $t - 1$:

$$x_{t-1}^{(\text{grees})} = (\Delta_{t-1}, \Gamma_{t-1}, v_{t-1}, \Theta_{t-1}, \rho_{t-1}).$$

Les sensibilités sont décalées d’un jour ($t - 1$) afin d’éviter toute fuite d’information, le modèle ne disposant que des valeurs connues au moment de la décision.

Famille dérivée $drisk_core + \rho$. En complément du jeu précédent (T12), on définit une représentation pondérée par les chocs de risque :

$$\begin{aligned} d_{\Delta,t} &= \Delta_{t-1} \Delta S_t, & d_{v,t} &= v_{t-1} \Delta IV_t, \\ d_{\Theta,t} &= \Theta_{t-1} \Delta t, & d_{\rho,t} &= \rho_{t-1} \Delta r_t. \end{aligned} \quad (2.1)$$

Ces termes $d_{\bullet,t}$ représentent les *contributions instantanées attendues* au ΔV_t selon une approximation linéaire :

$$\Delta V_t \approx d_{\Delta,t} + d_{v,t} + d_{\Theta,t} + d_{\rho,t},$$

où chaque produit combine la *sensibilité* du portefeuille à $t - 1$ et le *choc observé* du facteur à t . Cette formulation, inspirée de la théorie du risque local, permet d'ancrer la dynamique du P&L dans l'espace des variables de risque plutôt que dans l'espace purement observé des prix.

Cible d'apprentissage. Pour chaque séquence S_t , la variable à prédire est le **P&L journalier** :

$$y_t = P\&L_t = P_t^{\text{moy}} - P_{t-1}^{\text{moy}} = \frac{1}{2}((P_t^{\text{bid}} + P_t^{\text{ask}}) - (P_{t-1}^{\text{bid}} + P_{t-1}^{\text{ask}})). \quad (2.2)$$

Formalisme des séquences. L'entrée du modèle est un tenseur

$$X = (x_{t-L+1}, \dots, x_t) \in \mathbb{R}^{L \times p},$$

et la sortie associée est un scalaire $y_t \in \mathbb{R}$. L'apprentissage consiste à approximer la fonction de projection temporelle

$$f_{\theta} : \mathbb{R}^{L \times p} \longrightarrow \mathbb{R}, \quad f_{\theta}(X_t) \approx y_t,$$

où θ désigne l'ensemble des paramètres du modèle (réseau récurrent ou arbre de gradient).

Remarque. Les variables sont normalisées à partir des statistiques de l'ensemble d'apprentissage :

$$x'_t = \frac{x_t - \mu_{\text{train}}}{\sigma_{\text{train}}},$$

ce qui garantit la cohérence entre splits et évite les effets de fuite (*data leakage*).

2.3.3 Spécifications des modèles

L'objectif est d'apprendre une fonction de projection temporelle

$$f_{\theta} : \mathbb{R}^{L \times p} \rightarrow \mathbb{R}, \quad y_t = f_{\theta}(X_t) + \varepsilon_t,$$

où $X_t = (x_{t-L+1}, \dots, x_t)$ désigne la séquence d'entrée de longueur L , et y_t la variation journalière du P&L (cf. équation (2.2)). Les paramètres θ sont estimés par minimisation d'une fonction de perte $\mathcal{L}_{\delta}(y_t, f_{\theta}(X_t))$ sur l'ensemble d'apprentissage.

Trois familles de modèles sont retenues :

- (i) les **réseaux neuronaux récurrents séquentiels** (LSTM, GRU, GRU+Attention) pour capturer les dépendances temporelles du P&L;
- (ii) le **modèle XGBoost**, servant de référence non séquentielle, pour évaluer l'apport de la mémoire temporelle;
- (iii) le **pricer binomial CRR**, utilisé uniquement pour la validation de cohérence (section 3).

(i) Réseaux neuronaux récurrents. Les modèles séquentiels apprennent une transformation dynamique entre les états successifs x_t et un vecteur caché h_t représentant la mémoire du système. Chaque couche récurrente réalise l'opération générique :

$$h_t = g_\theta(x_t, h_{t-1}),$$

où $g_\theta(\cdot)$ est une fonction paramétrée spécifique à l'architecture choisie.

LSTM (Long Short-Term Memory). Le LSTM introduit trois portes de régulation — d'entrée, d'oubli et de sortie — qui contrôlent le flux d'information à travers le temps.

$$\begin{aligned} f_t &= \sigma(W_f[h_{t-1}, x_t] + b_f), \quad i_t = \sigma(W_i[h_{t-1}, x_t] + b_i), \\ \tilde{C}_t &= \tanh(W_C[h_{t-1}, x_t] + b_C), \quad C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t, \\ o_t &= \sigma(W_o[h_{t-1}, x_t] + b_o), \quad h_t = o_t \odot \tanh(C_t). \end{aligned} \quad (2.3)$$

Le vecteur h_t représente la mémoire courte et C_t la mémoire longue de la séquence.

GRU (Gated Recurrent Unit). Le GRU simplifie cette architecture en fusionnant certaines portes, avec deux contrôleurs principaux :

$$\begin{aligned} z_t &= \sigma(W_z[h_{t-1}, x_t]), \quad r_t = \sigma(W_r[h_{t-1}, x_t]), \\ \tilde{h}_t &= \tanh(W_h[r_t \odot h_{t-1}, x_t]), \quad h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t. \end{aligned} \quad (2.4)$$

Le GRU est moins coûteux en paramètres tout en maintenant une performance similaire au LSTM pour des horizons temporels moyens.

GRU avec mécanisme d'attention. Afin d'accorder un poids différencié aux pas temporels les plus déterminants, un module d'attention est ajouté :

$$e_t = v^\top \tanh(W_h h_t + b), \quad a_t = \frac{\exp(e_t)}{\sum_{k=1}^L \exp(e_k)}, \quad \hat{h} = \sum_{t=1}^L a_t h_t. \quad (2.5)$$

La représentation $\hat{h}$ résume la séquence en mettant l'accent sur les instants les plus influents dans la formation du P&L.

Enfin, une couche linéaire transforme le dernier état caché (ou la combinaison pondérée $\hat{h}$) en la prédiction $\hat{y}_t$.

(ii) Modèle XGBoost. Le modèle *Extreme Gradient Boosting* repose sur une somme d'arbres de décision :

$$\hat{y}_t = \sum_{k=1}^K f_k(x_t), \quad f_k \in \mathcal{F}, \quad (2.6)$$

où chaque f_k minimise une fonction de perte régularisée :

$$\mathcal{L}(\phi) = \sum_i l(y_i, \hat{y}_i) + \sum_k \Omega(f_k),$$

avec $\Omega(f_k)$ un terme de pénalisation contrôlant la complexité des arbres. Le modèle XGBoost sert de *baseline* non séquentielle : il ignore la dépendance temporelle et évalue la performance prédictive liée uniquement aux relations statiques entre variables.

(iii) Fonction de perte et optimisation. Tous les modèles sont entraînés à minimiser la **Huber Loss**, robuste aux valeurs extrêmes :

$$\mathcal{L}_\delta(y, \hat{y}) = \begin{cases} \frac{1}{2}(y - \hat{y})^2, & \text{si } |y - \hat{y}| \leq \delta, \\ \delta|y - \hat{y}| - \frac{1}{2}\delta^2, & \text{sinon.} \end{cases} \quad (2.7)$$

Les paramètres sont optimisés via l'algorithme AdamW avec apprentissage adaptatif. Les modèles séquentiels utilisent la précision mixte (*Automatic Mixed Precision, AMP*) afin d'accélérer les calculs sur GPU tout en réduisant la consommation mémoire.

(iv) Hyperparamètres principaux.

- Réseaux récurrents : deux couches cachées (64 unités), *dropout* $p \in \{0.2, 0.3, 0.4, 0.5\}$, longueur de séquence $L \in \{4, 6, 8\}$, taux d'apprentissage $lr \in \{10^{-3}, 3 \times 10^{-4}\}$, régularisation $wd = 10^{-4}$.
- XGBoost : profondeur maximale = 6, taux d'apprentissage = 0.1, nombre d'arbres $K = 500$, régularisation $\lambda = 1$.

L'ensemble de ces modèles fournit une base cohérente pour évaluer la capacité du *Deep Learning explicable* à reproduire les dynamiques du P&L et à surpasser les décompositions analytiques classiques.

2.3.4 Entraînement, réglages et sélection

Procédure d'entraînement. Soient y_t la valeur observée du P&L et $\hat{y}_t = f_\theta(X_t)$ sa prédiction. L'apprentissage consiste à minimiser la fonction de perte moyenne :

$$\mathcal{J}(\theta) = \frac{1}{N_{\text{train}}} \sum_{t \in \mathcal{D}_{\text{train}}} \mathcal{L}_\delta(y_t, \hat{y}_t), \quad (2.8)$$

où $\mathcal{L}_\delta$ est la Huber Loss définie en (2.7). Cette perte assure une pénalisation quadratique pour les écarts faibles et linéaire pour les erreurs extrêmes, ce qui limite l'influence des journées de marché atypiques.

Les gradients $\nabla_\theta \mathcal{J}$ sont calculés par rétropropagation et mis à jour par l'optimiseur AdamW, avec un taux d'apprentissage initial $lr_0 = 10^{-3}$ et une décroissance adaptative (*ReduceLROnPlateau*) dès que la perte de validation stagne.

Contrôles de convergence. Deux mécanismes de régularisation sont mis en place :

- Dropout aléatoire : chaque couche récurrente désactive une fraction $p \in [0.2, 0.5]$ des neurones à chaque itération afin de réduire le sur-apprentissage ;

- Early stopping : l'entraînement s'arrête automatiquement lorsque la perte de validation ne s'améliore plus après 15 époques consécutives.

La combinaison de ces contrôles assure une convergence stable tout en limitant la variance du modèle.

Sélection du modèle. Chaque modèle est évalué sur $\mathcal{D}_{\text{test}}$ à l'aide des métriques standards de régression :

$$\text{MAE} = \frac{1}{N} \sum_t |y_t - \hat{y}_t|, \quad \text{RMSE} = \sqrt{\frac{1}{N} \sum_t (y_t - \hat{y}_t)^2}, \quad R^2 = 1 - \frac{\sum_t (y_t - \hat{y}_t)^2}{\sum_t (y_t - \bar{y})^2}.$$

Les modèles sont également soumis au *P&L Attribution Test (PLA)* défini dans le cadre du FRTB (2.17)

Critère de choix final. Le modèle retenu doit simultanément :

- (i) minimiser le RMSE et le MAE sur l'échantillon de test ;
- (ii) maximiser le R^2 et la corrélation ρ avec le HPL observé ;
- (iii) respecter les bornes réglementaires du test PLA (typiquement : $\rho_{\min} = 0.8$, $KS_{\max} = 0.1$).

Le modèle satisfaisant l'ensemble de ces critères, notamment en maintenant une stabilité temporelle des performances, est sélectionné comme modèle explicable de référence.

2.3.5 Construction des séries PLA de référence

Le *P&L Attribution Test (PLA)* défini par le cadre réglementaire du *Fundamental Review of the Trading Book (FRTB)* repose sur la comparaison entre :

- le Risk Theoretical P&L (RTPL), produit par le modèle interne de risque (ici, les modèles d'apprentissage) ;
- et le Hypothetical P&L (HPL), obtenu à partir d'un portefeuille tenu constant et valorisé selon un modèle de référence.

Ces deux séries constituent la base de la validation de modèle et des tests de cohérence statistique.

(1) Hypothetical P&L fondé sur les prix de marché. Le premier indicateur HPL_{mid} est directement calculé à partir des prix observés en utilisant la moyenne des cotations acheteur-vendeur :

$$HPL_{\text{mid},t} = P_t^{\text{mid}} - P_{t-1}^{\text{mid}}, \quad P_t^{\text{mid}} = \frac{1}{2} (P_t^{\text{bid}} + P_t^{\text{ask}}). \quad (2.9)$$

Cette mesure représente la variation de valeur d'un portefeuille tenu constant entre deux dates successives. Elle est considérée comme la référence empirique principale du test PLA.

(2) Hypothetical P&L via pricers analytiques. Pour garantir la robustesse des comparaisons, un second HPL est calculé à l'aide de modèles de valorisation fermés :

le **pricer de Black–Scholes (BS)** et son pendant binomial **Cox–Ross–Rubinstein (CRR)**.

Black–Scholes. Pour un call européen sans dividende, la valeur théorique à la date t est donnée par :

$$C(S_t, t) = S_t N(d_1) - Ke^{-r(T-t)} N(d_2), \quad (2.10)$$

avec :

$$d_1 = \frac{\ln(S_t/K) + (r + \frac{1}{2}\sigma^2)(T-t)}{\sigma\sqrt{T-t}}, \quad d_2 = d_1 - \sigma\sqrt{T-t}, \quad (2.11)$$

où S_t est le prix du sous-jacent, K le prix d'exercice, σ la volatilité implicite, r le taux sans risque et $N(\cdot)$ la fonction de répartition normale centrée réduite. Le P&L théorique correspondant s'écrit :

$$HPL_{BS,t} = C(S_t, t) - C(S_{t-1}, t-1). \quad (2.12)$$

Cox–Ross–Rubinstein (CRR). Pour contrôler l'effet d'américanité, un modèle binomial est également implémenté. Il repose sur les paramètres :

$$u = e^{\sigma\sqrt{\Delta t}}, \quad d = \frac{1}{u}, \quad p = \frac{e^{r\Delta t} - d}{u - d}, \quad (2.13)$$

où u et d représentent respectivement les facteurs de hausse et de baisse du prix du sous-jacent. Le prix d'une option américaine est obtenu par induction arrière :

$$V_t^{\text{CRR}} = e^{-r\Delta t} (pV_u + (1-p)V_d), \quad (2.14)$$

et le P&L associé :

$$HPL_{\text{CRR},t} = V_t^{\text{CRR}} - V_{t-1}^{\text{CRR}}. \quad (2.15)$$

Le CRR sert ici de contrôle numérique pour les cas d'options américaines, tandis que le BS constitue le pricer de référence.

(3) Risk Theoretical P&L des modèles internes. Les modèles d'apprentissage (LSTM, GRU, XGBoost) fournissent des estimations du Risk Theoretical P&L (RTPL) :

$$RTPL_{\text{ML},t} = \widehat{P\&L}_t = f_\theta(X_t), \quad (2.16)$$

où f_θ désigne le modèle entraîné sur les variables de marché et de sensibilité. Cette série est comparée à HPL_{mid} et HPL_{BS} dans le cadre du test PLA.

(4) Test PLA et validation du cadre. La cohérence entre modèle interne et marché est évaluée à l'aide des deux critères réglementaires :

$$\rho(RTPL, HPL) \geq \rho_{\min}, \quad KS(RTPL, HPL) \leq KS_{\max}, \quad (2.17)$$

où ρ est la corrélation de Spearman entre les variations quotidiennes et KS la statistique du test de Kolmogorov–Smirnov mesurant l'écart entre les distributions empiriques.

Le respect simultané de ces deux seuils ($\rho_{\min} \approx 0.8$, $KS_{\max} \approx 0.1$ selon le BCBS bcbs2019mar32) confirme que la série prédite $RTPL_{\text{ML}}$ reproduit fidèlement la dynamique de marché observée.

Ce dispositif PLA forme la base de référence méthodologique : le HPL_{mid} représente la vérité de marché, les modèles BS/CRR assurent la cohérence analytique, et le $RTPL_{\text{ML}}$ fournit la projection explicable des variations quotidiennes du portefeuille. L'ensemble est ensuite utilisé pour l'attribution factorielle (XAI, OAT, SU, ASU) et les comparaisons croisées du chapitre 3.

2.3.6 Méthode d'explicabilité (SHAP)

L'explicabilité vise à relier les variations prédites du *Risk Theoretical P&L* ($RTPL_{\text{ML}}$) aux facteurs de risque sous-jacents du portefeuille. Nous utilisons pour cela la méthode SHAP (*SHapley Additive exPlanations*), fondée sur la théorie des jeux coopératifs.

(1) Principe. Toute prédiction $f(x)$ d'un modèle peut être décomposée en une somme additive :

$$f(x) = \phi_0 + \sum_{i=1}^n \phi_i(x), \quad (2.18)$$

où :

- $\phi_0 = \mathbb{E}[f(X)]$ est la valeur de base du modèle sur l'ensemble de référence,
- $\phi_i(x)$ est la contribution marginale du facteur x_i à la prédiction.

Les valeurs de Shapley satisfont les trois axiomes de *symétrie*, *efficacité* et *additivité*, garantissant une attribution équitable et cohérente entre variables.

(2) Approximation différentiable : GradientSHAP. Le calcul exact des valeurs de Shapley étant combinatoire (2^n sous-ensembles), nous utilisons la méthode GradientSHAP, qui repose sur une approximation par intégration des gradients :

$$\phi_i(x) \approx \mathbb{E}_{z \sim p(z)} \left[(x_i - z_i) \int_0^1 \frac{\partial f(z + \alpha(x - z))}{\partial x_i} d\alpha \right], \quad (2.19)$$

où z est un *background* aléatoire tiré d'une distribution de référence $p(z)$. Cette formulation, inspirée des *Integrated Gradients*, permet d'estimer les contributions continues de chaque variable dans un modèle neuronal différentiable.

(3) Configuration expérimentale. Les attributions SHAP sont calculées pour le modèle LSTM/GRU sélectionné, sur la dernière étape temporelle t de chaque séquence, correspondant au P&L journalier. Deux ensembles de référence (*backgrounds*) sont utilisés :

- (i) un fond *zéro + bruit gaussien* normalisé (znb, $N = 2048$);
- (ii) un fond empirique, constitué d'un sous-échantillon moyen du jeu d'apprentissage.

L'univers explicatif (*manifeste*) couvre 95 jours en 2022, sélectionnés pour représenter différents régimes de volatilité et de variations extrêmes de HPL_{mid} . Au total, environ 57 000 instruments et 46 000 séquences ont été traités avec un `batch size` de 4096 et $n_{\text{samples}} = 8$.

(4) Regroupement factoriel et agrégation. Les contributions élémentaires $\phi_i(x)$ sont regroupées selon les quatre familles de risque principales :

$$\Delta \leftrightarrow d_\Delta, \quad \nu \leftrightarrow d_\nu, \quad \theta \leftrightarrow d_\Theta, \quad \rho \leftrightarrow d_\rho,$$

telles que définies en (2.1). Les variables résiduelles sont classées dans la composante *other*, comprenant les états de marché, les chocs et les sensibilités retardées.

Les contributions sont ensuite agrégées au niveau *jour* (d) pour obtenir la série reconstituée :

$$\hat{y}_{\text{recons}}(d) = \phi_0 N_d + \sum_i \sum_{j \in \mathcal{J}_d} \phi_i(x_j), \quad \hat{y}_{\text{model}}(d) = \sum_{j \in \mathcal{J}_d} \widehat{P\&L}(x_j), \quad (2.20)$$

où N_d est le nombre d'observations du jour d et $\mathcal{J}_d$ l'ensemble des séquences correspondantes.

(5) Contrôles de cohérence. Deux vérifications sont effectuées :

- **Complétude additive** : la somme des contributions doit reconstituer la sortie du modèle, $\sum_i \phi_i(x) \approx f(x) - \phi_0$;
- **Cohérence économique** : les contributions agrégées sont corrélées aux proxys analytiques :

$$\begin{aligned} &\text{Corr}(\text{SHAP}_\Delta, \Delta S \cdot \Delta), \quad \text{Corr}(\text{SHAP}_\nu, \Delta IV \cdot \nu), \\ &\text{Corr}(\text{SHAP}_\Theta, \Delta t \cdot \Theta), \quad \text{Corr}(\text{SHAP}_\rho, \Delta r \cdot \rho). \end{aligned}$$

Cette approche explicable permet d'associer chaque variation prédite du P&L à des facteurs économiques interprétables, tout en respectant les propriétés d'efficacité et de symétrie des attributions analytiques. Les séries journalières agrégées servent ensuite de base à la comparaison avec les décompositions OAT, SU et ASU décrites dans la section 2.3.7.

2.3.7 Attributions analytiques (OAT, SU, ASU)

Les méthodes analytiques d'attribution du P&L visent à décomposer la variation de valeur d'un portefeuille en contributions élémentaires associées à des chocs appliqués aux variables d'état du modèle de prix. Elles constituent le cadre de référence théorique auquel les attributions explicables (XAI) sont comparées.

(1) Cadre conceptuel. Soit $P(S_t, \sigma_t, r_t, T_t)$ la fonction de valorisation d'une option à la date t , où S désigne le prix du sous-jacent, σ la volatilité implicite, r le taux sans risque et T le temps à maturité. La variation totale de prix entre deux jours successifs s'écrit :

$$\Delta P_t = P(S_t, \sigma_t, r_t, T_t) - P(S_{t-1}, \sigma_{t-1}, r_{t-1}, T_{t-1}). \quad (2.21)$$

L'objectif de l'attribution est d'exprimer ΔP_t comme somme de contributions partielles liées à chaque facteur de risque.

(2) OAT — One-at-a-Time. La méthode *One-at-a-Time* met à jour chaque variable individuellement à partir de son état initial $P_0 = P(S_{t-1}, \sigma_{t-1}, r_{t-1}, T_{t-1})$:

$$C_S = P(S_t, \sigma_{t-1}, r_{t-1}, T_{t-1}) - P_0, \quad (2.22)$$

$$C_\sigma = P(S_{t-1}, \sigma_t, r_{t-1}, T_{t-1}) - P_0, \quad (2.23)$$

$$C_r = P(S_{t-1}, \sigma_{t-1}, r_t, T_{t-1}) - P_0, \quad (2.24)$$

$$C_T = P(S_{t-1}, \sigma_{t-1}, r_{t-1}, T_t) - P_0. \quad (2.25)$$

La somme de ces quatre termes ne reproduit pas exactement ΔP_t , car les effets d'interaction ne sont pas pris en compte. Le résidu d'inexactitude est défini par :

$$R^{\text{oat}} = \Delta P_t - (C_S + C_\sigma + C_r + C_T). \quad (2.26)$$

La méthode OAT est simple à implémenter mais peut présenter un biais directionnel.

(3) SU — Sequential Updating. La méthode *Sequential Updating* applique successivement les chocs sur les variables dans un ordre donné $\pi = (f_1, \dots, f_4)$ avec $f_k \in \{S, \sigma, r, T\}$:

$$C_{f_k}^{\text{su}, \pi} = P(\text{chocs } f_1 \dots f_k) - P(\text{chocs } f_1 \dots f_{k-1}), \quad \sum_{k=1}^4 C_{f_k}^{\text{su}, \pi} = \Delta P_t. \quad (2.27)$$

Cette décomposition est exacte pour un ordre π donné, mais les contributions peuvent varier selon la séquence choisie, ce qui introduit une dépendance à l'ordre.

(4) ASU — Average Sequential Updating. Pour éliminer cette dépendance, la méthode *Average Sequential Updating* (ASU) moyenne les décompositions obtenues sur toutes les permutations possibles :

$$C_i^{\text{asu}} = \frac{1}{4!} \sum_{\pi} C_i^{\text{su}, \pi}. \quad (2.28)$$

Cette approche, équivalente à la valeur de Shapley en *variable-space*, satisfait les axiomes d'efficacité et de symétrie :

$$\sum_i C_i^{\text{asu}} = \Delta P_t, \quad C_i^{\text{asu}}(S, \sigma, r, T) = C_i^{\text{asu}}(\pi(S, \sigma, r, T)).$$

L'ASU constitue ainsi la référence analytique pour les comparaisons ultérieures avec XAI.

(5) Implémentation numérique. Les calculs analytiques sont effectués sous deux modèles de valorisation :

- le modèle **Black–Scholes** pour les calls européens sans dividende, selon les équations (2.10)–(2.11);
- le modèle **Cox–Ross–Rubinstein (CRR)** pour contrôler les effets d'américanité.

Chaque contrat est réévalué entre $t-1$ et t à partir des variables observées (S, σ, r, T) , puis agrégé par jour :

$$\text{PnL}_{\text{desk}}(t) = \sum_{j=1}^{N_t} (P_{j,t} - P_{j,t-1}) = \sum_{i \in \{S, \sigma, r, T\}} \sum_{j=1}^{N_t} C_{i,j}^{\text{asu}}.$$

Avant le calcul, des vérifications de cohérence sont appliquées afin d'éviter les erreurs numériques : on s'assure que la volatilité implicite et la maturité restent strictement positives ($\sigma > 0$, $T > 0$), et que toutes les dates sont arrondies au jour le plus proche, afin de garantir la correspondance exacte entre les valeurs observées à la veille et celles du jour.

(6) Contrôles. Deux critères sont vérifiés :

- (i) Efficacité : $\sum_i C_i^{\text{asu}} = \Delta P_t$ à la précision machine ;
- (ii) Stabilité à l'ordre : réduction de l'écart-type SU-ASU par facteur supérieur à 10.

Ces contrôles garantissent la comparabilité directe entre les approches, et posent les fondations pour l'analyse croisée des contributions par facteur de risque.

2.3.8 Alignement XAI-ASU et métriques de comparaison

Cette section décrit la procédure d'alignement entre les contributions issues des approches explicables (XAI) et analytiques (ASU), ainsi que les métriques retenues pour quantifier leur cohérence.

(1) Alignement des univers. Les séries XAI $(\Delta, \nu, \theta, \rho)$ et analytiques (S, σ, r, T) sont restreintes à un univers commun de 95 jours et 57 000 instruments, de manière à garantir la comparabilité des résultats. Les correspondances instrument/date sont imposées :

$$\forall d, \quad \mathcal{J}_d^{\text{XAI}} = \mathcal{J}_d^{\text{ASU}}.$$

(2) Métriques de comparaison. Les concordances sont évaluées à trois niveaux :

- Global (P&L total) : corrélation de Spearman et statistique KS entre $RTPL_{\text{ML}}$, PnL_{ASU} et HPL_{mid} .
- Factoriel $(\Delta, \nu, \theta, \rho)$: corrélations de Pearson/Spearman et régression linéaire $\text{ASU} = \beta_0 + \beta_1 \text{XAI}$.
- Erreur moyenne absolue et quadratique :

$$\text{MAE} = \frac{1}{n} \sum_{t=1}^n |XAI_t - ASU_t|, \quad \text{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n (XAI_t - ASU_t)^2}.$$

Une corrélation forte ($\rho > 0.95$) et un faible RMSE indiquent que les deux méthodes capturent une dynamique similaire du P&L. Des écarts localisés sont analysés en fonction des segments de marché (moneyness, maturité, volatilité).

Ce protocole d'alignement et de mesure permet d'établir une base de comparaison rigoureuse entre les approches explicables et analytiques. Il sert de cadre d'évaluation pour les résultats présentés au chapitre 3.

Conclusion

Ce chapitre a présenté les données, les outils et la méthodologie retenus : construction du cadre de référence (HPL/RTPL), modélisation prédictive (LSTM/GRU, XGBoost), attribution explicable (SHAP) et décompositions analytiques (OAT, SU, ASU) en Black–Scholes. Les critères d'évaluation définis (fidélité, cohérence, stabilité, multi-granularité) serviront au chapitre suivant pour analyser et comparer les résultats.

RÉSULTATS ET DISCUSSION

3.1 Introduction

Ce chapitre présente les résultats empiriques obtenus sur l'année 2022. Nous évaluons d'abord la modélisation prédictive du *Risk Theoretical P&L* ($RTPL_{ML}$), puis analysons les erreurs par familles de situations (moneyness, maturité, volatilité). Nous examinons ensuite l'attribution explicable (*Explainable Artificial Intelligence* – XAI, méthode SHAP) et la confrontons aux décompositions analytiques (OAT, SU, ASU) sur un univers strictement aligné. Enfin, une discussion met ces résultats en perspective avec la littérature.

3.2 Résultats de la modélisation prédictive du P&L

3.2.1 Évaluation et validation des modèles prédictifs

Les résultats obtenus lors de la modélisation du *Risk Theoretical P&L* ($RTPL_{ML}$) à l'aide des architectures séquentielles LSTM et GRU, ainsi que du modèle non séquentiel XGBoost utilisé comme référence sont présentés ici. L'évaluation a été réalisée sur la période 2022 afin de mesurer la capacité de chaque approche à reproduire les variations observées du *Hypothetical P&L* (HPL) et leur conformité au *P&L Attribution Test* (PLA).

Comparaison des performances des modèles

Deux configurations de variables ont été testées :

- T12 : variables de marché classiques (prix, volatilité implicite, maturité, moneyness, taux sans risque, variations quotidiennes et sensibilités à $t-1$);
- DRISK_core+ : version enrichie intégrant les produits de chocs ($d_{\Delta}, d_v, d_{\Theta}, d_{\rho}$), permettant de matérialiser directement les effets de risque.

Les performances des modèles ont été évaluées selon cinq critères : l'erreur quadratique moyenne (RMSE), l'erreur absolue moyenne (MAE), le coefficient de détermination (R^2), la corrélation quotidienne (ρ) et la statistique de Kolmogorov–Smirnov (KS) utilisée dans le test PLA. Les résultats sont synthétisés dans le tableau 3.1.

TABLE 3.1 – Performances prédictives des modèles sur l'année 2022.

Modèle	Variables	L	RMSE	MAE	R^2	ρ	KS	Résultat PLA
LSTM	DRISK_core+	6	0.768	0.391	0.972	0.996	0.064	Passe
GRU	T12	6	0.860	0.546	0.965	0.990	0.064	Passe
LSTM	T12	8	1.125	0.662	0.941	0.987	0.044	Passe
GRU	T12	8	0.953	0.558	0.958	0.992	0.069	Passe
XGB	DRISK_core+	–	1.015	0.562	0.951	0.990	0.072	Passe
XGB	T12	–	1.866	1.156	0.835	0.973	0.104	Échec

Le modèle **LSTM (L=6, DRISK_core+ ρ)** se distingue nettement avec un RMSE de 0.768 et un R^2 de 0.972, indiquant une excellente précision dans la reproduction des variations du P&L. La statistique KS = 0.064 situe le modèle dans la zone *verte* du test PLA, confirmant la conformité réglementaire. La configuration T12 à L=8 obtient un KS légèrement meilleur (0.044) mais au prix d'une erreur globale plus élevée. Le compromis entre stabilité et exactitude conduit donc à retenir le modèle LSTM L=6 | DRISK_core+ comme configuration optimale pour la suite de l'analyse.

Validation du test PLA et diagnostic visuel

Les comparaisons quotidiennes entre $RTPL_{ML}$ et HPL_{mid} montrent une corrélation moyenne très élevée ($\rho_{\text{Pearson}} \approx 0.992$, $\rho_{\text{Spearman}} \approx 0.991$), attestant la fidélité du modèle à la dynamique de marché. La figure 3.1 illustre la superposition quasi parfaite des séries de P&L, où la courbe prédite $RTPL_{ML}$ suit étroitement les trajectoires de référence HPL_{mid} et HPL_{pricer} , avec seulement quelques écarts ponctuels lors de journées de forte volatilité.




FIGURE 3.1 – Séries quotidiennes : $RTPL_{ML}$ (prédit) vs HPL_{mid} (référence marché) et HPL_{pricer} (pricer).

Le graphique de gauche de la figure 3.2 illustre une forte concordance entre $RTPL_{ML}$ et HPL_{mid} , les points étant globalement alignés le long de la diagonale $y = x$. Cependant, la distribution cumulative (ECDF) des résidus, à droite, présente une

légère asymétrie : la queue droite est plus étendue que la gauche, et la courbe croise l'axe des abscisses au-dessus de 0.5, indiquant une médiane légèrement négative. Cela traduit un faible biais : le modèle tend à sur-prédire la médiane des jours ordinaires tout en sous-estimant certains pics extrêmes de P&L. L'intervalle contenant 95 % des erreurs dépasse légèrement $[-2000, 2000]$, mais reste cohérent avec la tolérance du test PLA.




FIGURE 3.2 – Diagnostic PLA : dispersion $RTPL_{ML}$ vs HPL_{mid} (gauche); distributions cumulées (ECDF) des résidus (droite).

En résumé, le modèle LSTM ($L=6$, DRISK_core+) reproduit fidèlement les fluctuations du P&L observé, tout en respectant les contraintes du test PLA. Sa combinaison de variables théoriques et de chocs réels assure une interprétation financière robuste et une bonne capacité de généralisation sur les données de marché.

3.3 Analyse des erreurs et diagnostic de robustesse

Cette section examine finement les écarts de prédiction du modèle retenu (LSTM, $L = 6$, DRISK_core+ ρ) selon trois dimensions opérationnelles : moneyness, maturité (DTE) et régime de volatilité implicite (IV). Sauf mention contraire, les erreurs sont mesurées par l'erreur absolue moyenne (MAE) et la racine de l'erreur quadratique moyenne (RMSE).

3.3.1 Erreurs par moneyness et maturité (DTE)

(3.3.1) Moneyness

TABLE 3.2 – Erreurs par tranche de moneyness — LSTM ($L = 6$, DRISK_core+ ρ).

Moneyness	n	MAE	RMSE	Taux de détection	Biais (vraiprédit)
OTM (0.9)	130 483	0.24	0.35	0.77	−0.16
ATM (0.9–1.0)	19 888	0.32	0.49	0.93	−0.03
ATM (1.0–1.1)	17 291	0.40	0.63	0.95	−0.01
ITM (1.1)	92 647	0.62	1.16	0.96	+0.14

Les options hors de la monnaie OTM (Out of The Money) présentent des erreurs faibles et un biais *conservateur* (légère surestimation des pertes), tandis que celles dans la monnaie ITM (In The Money) cumulent erreurs plus élevées et biais *optimiste* (sous-estimation des pertes), typiques d’une convexité plus marquée.

(3.3.1) Maturité (DTE)

TABLE 3.3 – Erreurs par tranche de maturité (jours) — LSTM ($L = 6$, DRISK_core+ ρ).

DTE (jours)	n	MAE	RMSE	Taux de détection	Biais
0–7	5 885	0.58	1.00	0.87	−0.07
8–30	32 804	0.41	1.05	0.89	−0.04
31–90	41 445	0.33	0.89	0.86	−0.03
90	180 175	0.39	0.66	0.86	+0.07

Le court terme ($DTE \leq 7$) concentre l’essentiel des difficultés (influence du Θ , *theta-decay*). Les maturités **moyennes à longues** stabilisent la dynamique de P&L et réduisent la variance des erreurs.




FIGURE 3.3 – Heatmap du MAE selon la moneyness et la maturité (DTE) — LSTM ($L = 6$, DRISK_core+ ρ).

La matrice *moneyness* × *DTE* confirme un régime d’erreurs faibles pour les OTM à maturités moyennes/longues, et un régime d’erreurs élevées pour les ITM très proches de l’échéance.

3.3.2 Erreurs par régime de volatilité et extrêmes

Quartiles de volatilité implicite (IV)

TABLE 3.4 – Erreurs par quartiles de volatilité implicite — LSTM
($L = 6$, DRISK_core+ ρ).

IV (quartiles)	n	MAE	RMSE	Taux de détection	Biais
Q20 (faible)	52 084	0.34	0.56	0.83	−0.08
Q50 (médiane)	78 077	0.29	0.43	0.83	−0.13
Q80 (élevée)	78 087	0.36	0.63	0.88	0.00
Q100 (très haute)	52 061	0.63	1.32	0.92	+0.11

L’augmentation de la volatilité implicite s’accompagne d’une hausse du MAE/RMSE : le modèle reste précis en régimes calmes (Q20–Q50), mais devient légèrement *optimiste* en Q100 (tendance à sous-estimer l’ampleur des pertes en stress).

Extrêmes (top 1 % des résidus)

TABLE 3.5 – Analyse des extrêmes : seuil q_{99} , erreurs et détection des pertes — LSTM ($L = 6$, DRISK_core+ ρ).

q_{99}	MAE (queue)	RMSE (queue)	$n_{\text{top1\%}}$	Précision	Rappel	F_1
2.52	4.57	5.81	2 604	0.90	0.91	0.91

Les extrêmes correspondent principalement à des journées de volatilité marquée ou de retournements rapides. Malgré cela, la détection des pertes (événements $y \leq q_{0.05}$) reste robuste (Précision = 0.90, Rappel = 0.91, $F_1 = 0.91$).

Les analyses confirment trois points structurants :

- **Zones sensibles** : options *ITM* à *DTE court* et régimes d’IV *très haute* ;
- **Stabilité** : erreurs contenues et sans biais directionnel durable sur la majorité des configurations (OTM, DTE moyen/long) ;
- **Pertinence économique** : les schémas d’erreurs observés s’alignent avec la convexité (ITM) et le Θ -decay (échéances courtes).

Ces constats motivent l’usage d’une attribution explicable (section suivante) pour isoler les facteurs dominants dans les configurations les plus non linéaires.

3.4 Attribution explicable du P&L (méthode SHAP)

3.4.1 Exactitude et fidélité

Les attributions ont été calculées avec GradientSHAP (fond « znb » et fond moyen *train*) au dernier pas temporel de chaque séquence, puis agrégées au niveau *jour* (desk). Le contrôle de complétude additive montre une reconstitution quasi parfaite de la sortie modèle :

with_base (znb) : moy ≈ 1.002 , méd ≈ 1.000 no_base : méd ≈ 1.026

with_base (train, contrôle) : moy ≈ 1.055 .

TABLE 3.6 – Ratios de complétude des attributions (sans base / avec base).

Variante	Moyenne	Médiane	p ₁₀	p ₉₀
with_base (znb)	1.002	1.000	0.987	1.011
no_base (sans ϕ_0)	—	1.026	—	—
with_base (train, contrôle)	1.055	—	—	—

La somme des contributions reconstitue bien la prédiction du modèle ($\hat{y}_{\text{recons}} \approx \hat{y}_{\text{model}}$), ce qui autorise une analyse factorielle fiable.

3.4.2 Importance globale et segmentée des facteurs

L'analyse des contributions globales et segmentées permet d'identifier les facteurs de risque dominants dans la formation du P&L du portefeuille. Sur la période étudiée (2022), la somme des contributions signées (figure 3.4) met en évidence une domination nette du facteur directionnel Δ , responsable de plus de 80 % du P&L total. Ce résultat traduit un portefeuille fortement exposé au sous-jacent NVIDIA, donc très sensible aux variations du prix du marché. Les composantes associées à la volatilité (ν), au temps (θ) et au taux d'intérêt (ρ) présentent des effets secondaires mais cohérents sur le plan économique : ν et θ contribuent positivement en période de volatilité accrue ou d'échéance lointaine, tandis que ρ demeure négligeable à l'échelle quotidienne. Les composantes résiduelles (*other_state*, *other_shock*, *other_greeks_lag*) traduisent quant à elles des effets de second ordre et des interactions complexes entre variables de marché.

TABLE 3.7 – Mix global des contributions SHAP (somme signée 2022) et parts absolues.

Facteur	Somme signée	Part absolue
Δ	−86 865	82%
ν	+3 173	6%
θ	+3 446	2%
ρ	−157	0.2%
OTHER	+19 670	10%

Note : la composante OTHER se décompose en *other_state* (+12 861), *other_shock* (+6 251) et *other_greeks_lag* (+558).




FIGURE 3.4 – Somme des contributions signées par familles de facteurs ($\Delta, \nu, \theta, \rho$, autres).

Pour approfondir cette lecture, la figure 3.5 présente les contributions moyennes signées par niveau de moneyness (OTM, ATM, ITM). La structure reste stable : le facteur Δ conserve son influence dominante, plus marquée en zone *in-the-money* (ITM), où la convexité du prix de l'option amplifie la sensibilité directionnelle. À l'inverse, la composante θ devient légèrement négative à *at-the-money* (ATM), traduisant la dépréciation temporelle (*theta-decay*) sur les échéances courtes. La volatilité implicite (ν) compense partiellement cette perte, tandis que la composante *OTHER* augmente en ITM, reflétant des effets de marché contextuels.




FIGURE 3.5 – Contributions moyennes signées par niveau de moneyness (OTM/ATM/ITM).

En résumé, ces résultats démontrent que :

- le portefeuille NVDA est principalement Δ -driven, confirmant une exposition directionnelle dominante ;
- les effets de ν et θ jouent un rôle de régulation, réduisant la volatilité du P&L lors des phases extrêmes de marché ;
- les contributions liées aux taux (ρ) et aux composantes résiduelles demeurent marginales, mais participent à la stabilité globale du modèle explicable.

3.4.3 Dynamique quotidienne agrégée (vision portefeuille)

L'analyse quotidienne agrégée montre que la somme des contributions SHAP ($\Delta, \nu, \theta, \rho, \text{OTHER}$) reconstitue avec précision le *Risk Theoretical P&L* (RTPL_{ML}),

conformément à la propriété d'additivité de la méthode. À l'échelle portefeuille, la série $RTPL_{ML}$ suit globalement le *Hypothetical P&L* de marché (HPL_{mid}), avec des écarts d'amplitude observés lors de certaines périodes de forte volatilité. Ces écarts s'expliquent notamment par l'atténuation des valeurs extrêmes induite par la fonction de perte de Huber, qui rend le modèle plus robuste mais légèrement moins réactif aux pics.

La hiérarchie factorielle demeure stable dans le temps : la composante Δ domine les mouvements du P&L, le facteur ν (*vega*) compense partiellement lors des hausses de volatilité, et θ (*theta-decay*) contribue négativement à mesure que l'échéance approche. Les effets de ρ et de la composante *OTHER* restent faibles sur l'ensemble de la période. Une lecture managériale d'un épisode baissier (début mars 2022) illustre cette cohérence économique : la baisse du sous-jacent explique la majeure partie de la perte, compensée en partie par la hausse de la volatilité, tandis que l'effet du temps amplifie la dépréciation.




FIGURE 3.6 – Contributions quotidiennes empilées et séries de référence ($RTPL_{ML}$, HPL_{mid}).

Ainsi, la dynamique quotidienne agrégée confirme la capacité du modèle explicable à reproduire les variations observées du P&L tout en maintenant une structure factorielle économiquement cohérente.

3.5 Comparaison XAI et attributions analytiques

Résultats des méthodes analytiques

Nous comparons les trois schémas analytiques classiques d'attribution du P&L : OAT (variations isolées), SU (mises à jour séquentielles) et ASU (moyenne des SU, ordre-indépendant).

La reconstitution du P&L par OAT ($P_4 - P_0 \stackrel{?}{=} \sum_i C_i^{oat}$) laisse un résidu important :

$$R^{oat} = (P_4 - P_0) - \sum_i C_i^{oat}.$$

Au niveau *desk* (journalier), le résidu relatif moyen atteint $|R^{oat}|/|P_4 - P_0| = 57.71\%$, la médiane = 50.62%, et les percentiles $P_{90} = 96.98\%$, $P_{95} = 107.05\%$. L'erreur

d'additivité moyenne (valeur absolue) est de 25.00 (unités de P&L). Ces niveaux signalent une forte non-additivité (effets croisés ignorés) et rendent OAT inadapté à une lecture PLA robuste.

TABLE 3.8 – OAT (Black–Scholes) : résidu relatif $|R^{\text{OAT}}|/|P_4 - P_0|$ et écart additif moyen.

	Moyenne	Médiane	P90	P95
$ R^{\text{OAT}} / P_4 - P_0 $	57.71%	50.62%	96.98%	107.05%

Contrôle additif : $|P_4 - P_0 - \sum_i C_i^{\text{OAT}}|$ moyen = 25.0014.

SU vs ASU : exactitude et ordre-indépendance. Nous évaluons ensuite SU (exact mais dépendant de l'ordre) et ASU (moyenne des 24 ordres, *ordre-indépendante*). Le contrôle d'efficacité d'ASU (somme des contributions = P&L total) est satisfait à la précision machine ($\sim 4 \times 10^{-16}$) sous pricers BS et CRR.

TABLE 3.9 – Écart SU–ASU (pricer Black–Scholes) : MAD et RMSE par facteur.

Facteur	MAD	RMSE
S	0.03599	0.11668
σ	0.04473	0.13881
r	0.00043	0.00123
T	0.03610	0.13580

TABLE 3.10 – Écart SU–ASU (pricer CRR, contrôle d'américanité) : MAD et RMSE par facteur.

Facteur	MAD	RMSE
S	0.03717	0.11709
σ	0.04593	0.13917
r	0.00043	0.00132
T	0.03639	0.13590

Les écarts SU–ASU sont faibles pour tous les facteurs, et quasi identiques entre pricers BS et CRR : (i) l'ordre de mise à jour influence peu SU, (ii) la moyenne séquentielle ASU stabilise les contributions et garantit l'*ordre-indépendance* et l'additivité exacte. En pratique, BS est retenu comme pricer de référence (coût/rapidité) et CRR comme contrôle d'américanité, les deux menant aux mêmes conclusions qualitatives.

3.5.1 Niveau global (desk) : test PLA et résidus

Au niveau *desk*, la série prédite $RTPL_{ML}$ (modèle explicable) est comparée au *Hypothetical P&L* de marché HPL_{mid} . Les indicateurs du *P&L Attribution Test* confirment une forte cohérence entre les deux séries : $\text{Spearman}_{XAI} \approx 0,99$ et $KS_{XAI} \approx 0,044$, contre $\text{Spearman}_{BS} \approx 0,98$ et $KS_{BS} \approx 0,10$ pour la décomposition analytique (ASU–BS). Ces valeurs traduisent une meilleure conformité de la méthode explicable à la distribution empirique du P&L observé.

Les histogrammes de la figure 3.7 montrent une dispersion légèrement plus compacte pour XAI que pour ASU-BS, ce qui reflète une meilleure adéquation au marché. Les deux distributions sont proches de zéro, mais présentent un léger décalage, indiquant un biais de niveau faible plutôt qu’une neutralité parfaite. Les écarts les plus marqués apparaissent lors des épisodes de forte volatilité, où les deux approches sous-estiment l’amplitude des variations : pour XAI, cette atténuation découle de la fonction de perte de Huber, tandis que pour ASU-BS, elle résulte de la linéarisation analytique et de l’absence de termes d’ordre supérieur dans le re-pricing.




FIGURE 3.7 – Histogrammes des résidus : $HPL_{\text{mid}} - RTPL_{\text{ML}}$ (gauche) et $HPL_{\text{mid}} - \text{pnl}_{\text{pricer}}$ (droite).

Les deux approches reproduisent fidèlement la dynamique du P&L de marché, mais la méthode explicable offre une meilleure cohérence statistique globale et une réponse plus équilibrée aux fluctuations quotidiennes.

3.5.2 Niveau facteur : corrélations et régressions

Nous comparons les contributions quotidiennes par facteur entre XAI et l’attribution analytique ASU sous pricer Black-Scholes. Les concordances sont mesurées par les corrélations (Pearson, Spearman) et une régression linéaire $ASU = \beta_0 + \beta_1 \cdot XAI$. Les erreurs moyennes (MAD) et quadratiques (RMSE) complètent le diagnostic.

TABLE 3.11 – Comparaison XAI-ASU (pricer Black-Scholes) : corrélations, biais et régressions par facteur.

Facteur	Pearson	Spearman	biais _{XAI-ASU}	MAD	RMSE	β_0	β_1
Δ	0.9957	0.9970	-379.9	548.26	802.75	593.28	1.2213
ν	0.9848	0.9615	-22.6	172.81	256.46	-9.46	1.9228
θ	0.4135	0.3775	191.26	191.26	197.17	-172.80	0.5155
ρ	0.2327	0.1457	-3.89	11.11	16.03	2.82	0.3875

Les facteurs Δ et ν présentent des corrélations très élevées ($r \approx 0.98$) et des pentes $\beta_1 \approx 1$, ce qui traduit une amplification analytique des grands chocs par le re-pricing exact (ASU), tandis que XAI restitue des extrêmes légèrement lissés (effet de la perte Huber). Les facteurs θ et ρ restent secondaires au pas quotidien : corrélations plus faibles et RMSE modérées, l’impact économique étant limité dans l’agrégation *desk*.

La même comparaison sous pricer CRR conduit à des valeurs très proches (mêmes ordres de grandeur pour corrélations, β_1 , MAD et RMSE), confirmant que l’américanité ne modifie pas les conclusions qualitatives.

3.5.3 Stabilité temporelle (mensuelle) — synthèse et illustrations

Afin d'évaluer la robustesse temporelle des concordances XAI–ASU, nous résumons d'abord les corrélations mensuelles (2022) par facteur via les statistiques *min–médiane–max* (tableau 3.12), puis nous illustrons deux contextes contrastés (janvier calme vs février volatil) au moyen de contributions empilées.

TABLE 3.12 – Corrélations mensuelles XAI–ASU (2022) par facteur : *min–médiane–max*.

Facteur	Pearson		Spearman	
	Min	Médiane	Min	Médiane
Δ	0.972	0.999	0.943	1.000
ν	0.781	0.991	0.800	0.965
θ	−0.266	0.510	−0.800	0.500
ρ	−0.582	0.230	−0.600	0.400

Δ conserve des corrélations très élevées (médianes proches de 1), signe d'une forte cohérence XAI–ASU sur la composante directionnelle. ν reste globalement élevé, avec hétérogénéité ponctuelle. θ et ρ présentent une variabilité plus marquée et un impact économique moindre au pas quotidien.

Comparaisons mensuelles empilées. Les figures 3.8 et 3.9 présentent deux contextes contrastés : janvier, caractérisé par une volatilité modérée, et février, marqué par des mouvements de marché plus amples. Dans les deux cas, les trajectoires de P&L issues du modèle explicable (XAI) et de la décomposition analytique (ASU–BS) reproduisent la dynamique générale du *Hypothetical P&L* de marché (HPL_{mid}). Les écarts d'amplitude observés lors des pics de février traduisent une sous-estimation commune des extrêmes. Côté XAI, cette atténuation provient de la fonction de perte de Huber, qui limite l'influence des valeurs atypiques ; côté ASU–BS, elle s'explique par la linéarisation des effets de second ordre (gamma, vega non linéaire) dans la décomposition analytique.




FIGURE 3.8 – Comparaison XAI vs ASU–BS — contributions journalières empilées (janvier 2022). Les deux approches suivent la dynamique de HPL_{mid} avec de faibles écarts d'échelle.




FIGURE 3.9 — Comparaison XAI vs ASU-BS — contributions journalières empilées (février 2022). En régime volatil, les deux méthodes sous-estiment l'amplitude des variations.

3.6 Discussion des résultats

Les résultats confirment la pertinence d’une approche hybride combinant apprentissage profond et interprétabilité pour l’attribution du *Profit and Loss* (P&L). Le modèle séquentiel LSTM, calibré sur les variables *DRISK_core+*, reproduit fidèlement la dynamique observée du P&L tout en respectant les critères du *P&L Attribution Test* (PLA). La corrélation élevée entre $RTPL_{ML}$ et HPL_{mid} , associée à une statistique de Kolmogorov–Smirnov contenue, traduit une conformité robuste au cadre réglementaire *FRTB – MAR/32* [31]. Ces constats confortent l’idée avancée par BÜHLER et al. [4] et ROSSI, COCCO et BORMETTI [3] selon laquelle les réseaux neuronaux profonds complètent la finance théorique en apprenant directement les régimes de marché complexes, sans en remettre en cause les fondements analytiques.

L’analyse des contributions SHAP révèle une structure économique claire et hiérarchisée : le facteur directionnel lié au sous-jacent domine le P&L, suivi des effets de la volatilité implicite et du passage du temps. Ces observations s’accordent avec celles de SHEN [25] et DJAGBA et NDIZIHIWE [32], qui montrent la capacité des réseaux récurrents de type GRU ou LSTM à capter la dépendance temporelle entre prix, volatilité et maturité dans le *pricing* d’options américaines. La faible influence du taux d’intérêt et la variabilité du facteur temporel (θ) observées ici sont cohérentes sur le plan conceptuel avec les cadres de décomposition de SCHILLING et al. [9] et JETSES et CHRISTIANSEN [8], lesquels soulignent que certaines composantes du risque ont un impact marginal à court horizon. Ces rapprochements demeurent toutefois théoriques : l’étude n’apporte pas de validation empirique directe sur ces effets.

Sur le plan analytique, la comparaison entre les décompositions explicables (XAI–LSTM) et analytiques (ASU–Black–Scholes) met en évidence une forte cohérence factorielle, avec des corrélations supérieures à 0.98 pour les facteurs directionnels et de volatilité. Ces résultats rejoignent les conclusions de FLAIG et JUNIKE [1] et de CHRISTIANSEN [2], qui démontrent que la méthode *Average Sequential Updating* (ASU) garantit à la fois l’exactitude additive et la symétrie des contributions. Les travaux récents de JETSES et CHRISTIANSEN [8] confirment cette propriété en temps continu, l’ASU discret constituant une approximation cohérente du schéma infinitésimal (IASU). Dans la pratique, comme l’ont souligné CANDLAND et LOTZ [11] et THOMPSON, LUO et FERGUSON [10], la dépendance à l’ordre dans les mises à jour séquentielles (*waterfall*) représente une difficulté opérationnelle majeure pour les desks soumis au test PLA. L’utilisation d’une moyenne séquentielle (ASU) ou d’un cadre de type Shapley-Shubik permet ainsi de réduire cette sensibilité et d’assurer des décompositions plus stables et auditables.

La convergence observée entre les approches analytiques et explicables reflète une tendance de fond visant à relier rigueur théorique et modélisation empirique. Les valeurs SHAP respectent les axiomes d’efficacité et d’additivité définis par LUNDBERG et LEE [5], tout en offrant une lecture locale des variations du P&L par facteur de risque. L’intégration de variantes prenant en compte la dépendance entre variables, comme celle proposée par AAS, JULLUM et LØLAND [23], constitue une perspective d’amélioration pour renforcer la robustesse et la cohérence statistique des explications. Enfin, les recommandations de FRITZ-MORGENTHAU, WEYDE et al. [28], CERNEVIČIENĖ et COAUTHORS [26] et du CFA INSTITUTE RESEARCH AND POLICY CENTER [29] soulignent l’importance d’ancrer ces approches explicables dans les cadres de gouvernance des modèles (MRM) et de conformité réglementaire, ce qui confère une dimension opérationnelle supplémentaire aux résultats obtenus.

En définitive, la présente étude montre qu'un modèle LSTM explicable, appuyé sur la méthode SHAP, peut restituer de manière cohérente la logique économique et analytique d'un cadre de décomposition du P&L. L'association entre modèle prédictif et modèle explicatif représente une avancée notable pour la gestion du risque de marché : elle permet une attribution transparente des sources de performance tout en répondant aux exigences du test PLA.

Conclusion

L'ensemble des analyses a montré que le modèle LSTM, entraîné sur les variables *DRISK_core+*, est celui qui reproduit le plus fidèlement la dynamique du *Hypothetical P&L* tout en respectant les critères du *P&L Attribution Test*. L'attribution explicable par la méthode SHAP a validé la cohérence interne du modèle et révélé une structure de risque dominée par le facteur directionnel Δ , suivi des composantes de volatilité et du temps. La comparaison entre l'approche explicable (XAI-LSTM) et la décomposition analytique (ASU-BS) met en évidence une convergence forte sur les facteurs clés, illustrant la complémentarité entre apprentissage profond et théorie du risque. Ces résultats confirment la viabilité des modèles d'intelligence artificielle explicables comme outils de validation et d'analyse conformes aux exigences du cadre réglementaire FRTB.

CONCLUSION GÉNÉRALE

Ce mémoire a proposé une approche hybride d'attribution du *Profit and Loss* (P&L), fondée sur la combinaison des réseaux de neurones profonds et de l'intelligence artificielle explicable (XAI), dans un cadre conforme aux exigences du *Fundamental Review of the Trading Book* (FRTB). L'objectif était de concilier la rigueur analytique des méthodes classiques d'attribution avec la flexibilité et la puissance de modélisation des réseaux de neurones, notamment le LSTM.

L'application à un portefeuille d'options américaines sur le titre NVIDIA a montré qu'un modèle explicable pouvait reproduire fidèlement la dynamique quotidienne du P&L tout en respectant les exigences du *P&L Attribution Test* (corrélation et test KS). L'introduction de variables pondérées par les sensibilités ($d_{\Delta}, d_v, d_{\Theta}, d_{\rho}$) a permis d'intégrer explicitement les facteurs de risque économiques dans l'apprentissage, assurant une meilleure cohérence entre théorie financière et apprentissage profond.

L'analyse explicable réalisée avec la méthode SHAP a mis en évidence que les variations du P&L sont principalement influencées par le mouvement du prix du sous-jacent, suivies des effets de volatilité et du passage du temps, tandis que le taux d'intérêt reste marginal. La comparaison avec la décomposition analytique (ASU–Black–Scholes) a révélé une forte concordance des contributions, confirmant que les modèles neuronaux explicables peuvent restituer la logique des méthodes analytiques tout en offrant une interprétation plus intuitive et opérationnelle.

Sur le plan pratique, cette approche permet aux institutions financières d'identifier clairement les sources de gains ou de pertes dans leurs portefeuilles, d'ajuster plus efficacement leurs stratégies de couverture et de renforcer la transparence vis-à-vis des autorités de supervision. Elle constitue aussi un outil d'aide à la décision permettant de relier les mouvements de marché aux expositions de risque réelles, améliorant ainsi la gestion quotidienne des portefeuilles.

Cependant, cette étude s'est limitée à un seul actif et à une granularité quotidienne, ce qui restreint la généralisation des résultats à d'autres classes d'actifs ou contextes de marché plus volatils. Des travaux futurs pourraient étendre l'analyse à des portefeuilles multi-actifs, à des fréquences plus fines ou à des horizons plus longs, et explorer des modèles attentionnels explicables ou probabilistes pour une interprétation encore plus riche. L'intégration de mesures comme la *Value-at-Risk* et l'*Expected Shortfall* dans le cadre d'attribution du P&L offrirait également une passerelle naturelle entre apprentissage automatique, mesure du risque et validation prudentielle.

En définitive, ce travail ouvre la voie à une finance plus robuste, transparente et interprétable, où les techniques d'intelligence artificielle contribuent à une meilleure compréhension et gestion des risques de marché.

RÉFÉRENCES BIBLIOGRAPHIQUES

- [1] S. FLAIG et G. JUNIKE. « Profit and Loss Attribution : An Empirical Study ». In : *European Actuarial Journal* 14.1 (2024), p. 1-28.
- [2] M. CHRISTIANSEN. « Profit and Loss Decomposition in Continuous Time and Approximations ». In : *European Actuarial Journal* 12 (2024), p. 29-56.
- [3] F. ROSSI, S. COCCO et G. BORMETTI. « Deep Learning P&L : Approximating Profit and Loss Distributions of Derivative Portfolios ». In : *arXiv preprint* (2020). arXiv : [2006.09955 \[q-fin.CP\]](#).
- [4] W. BÜHLER et al. « Deep Hedging ». In : *Quantitative Finance* 19.8 (2019), p. 1271-1291.
- [5] S. M. LUNDBERG et S.-I. LEE. « A Unified Approach to Interpreting Model Predictions ». In : *Advances in Neural Information Processing Systems* 30 (2017).
- [6] D. MOEHLE, S. BOYD et A. ANG. « Shapley Value Attribution for Portfolio Performance ». In : *arXiv preprint* (2021). arXiv : [2102.05799 \[q-fin.PM\]](#).
- [7] BASEL COMMITTEE ON BANKING SUPERVISION. *Minimum capital requirements for market risk*. Rapp. tech. Bank for International Settlements, jan. 2019.
- [8] J. JETSES et M. C. CHRISTIANSEN. « A General Surplus Decomposition Principle in Life Insurance ». In : *Scandinavian Actuarial Journal* 10 (2022), p. 901-925.
- [9] K. SCHILLING et al. « Decomposing Dynamic Risks into Risk Components ». In : *Management Science* 66.12 (2020), p. 5738-5756.
- [10] P. THOMPSON, J. LUO et M. FERGUSON. « The Profit-and-Loss Attribution Test : Design, Implementation and Pitfalls ». In : *Journal of Risk Model Validation* 12.1 (2018), p. 1-22.
- [11] M. CANDLAND et S. LOTZ. « Challenges in P&L Attribution under Basel III ». In : *Journal of Risk Model Validation* 8.2 (2014), p. 33-47.
- [12] T. R. BIELECKI et al. « Fair Estimation of Capital Risk Allocation ». In : *Statistics & Risk Modeling* 37.1-2 (2020), p. 1-24.
- [13] C. FREI. « A New Approach to Risk Attribution and Its Application in Credit Risk Analysis ». In : *Risks* 8.2 (2020), p. 65.
- [14] J.-F. MAI. *Performance Attribution with Respect to Interest Rates, FX, Carry, and Residual Market Risks*. 2023. arXiv : [2302.01010 \[q-fin.PM\]](#).
- [15] R. PIMENTEL, L. A. ALEXANDRE et A. SEBASTIÃO. « Option Pricing with Deep Learning : A Long Short-Term Memory Approach ». In : *Decisions in Economics and Finance* (2025).
- [16] Y. LIU, X. JIN et X. ZHANG. « Option Pricing Using LSTM : A Perspective of Realized Skewness ». In : *Mathematics* 11.2 (2023), p. 314.

- [17] J. CHEN et L. LI. « Data-Driven Hedging of Stock Index Options via Deep Learning ». In : *Operations Research Letters* 51 (2023), p. 391-398.
- [18] G. FATOUROS, K. PLIAKOS et al. « DeepVAR : A Framework for Portfolio Risk Assessment Using Deep Learning ». In : *Digital Finance* 5.1 (2023), p. 1-24.
- [19] F. BASCHETTI, A. DE MARCO et A. MICHELETTI. « Deep Calibration with Random Grids ». In : *Quantitative Finance* (2024).
- [20] C. QIAO et X. WAN. *Enhancing Black–Scholes Delta Hedging via Deep Learning*. 2024. arXiv : [2407.19367 \[q-fin.TR\]](#).
- [21] V. D. LOKESHWAR et S. JAIN. *Data-Driven Approach for Static Hedging of Exchange Traded Options*. 2023. arXiv : [2302.00728 \[q-fin.TR\]](#).
- [22] L. S. SHAPLEY. « A Value for n-Person Games ». In : *Contributions to the Theory of Games* 2 (1953), p. 307-317.
- [23] K. AAS, M. JULLUM et A. LØLAND. « Explaining Individual Predictions When Features Are Dependent : More Accurate Approximations to Shapley Values ». In : *Artificial Intelligence* 298 (2021), p. 103502.
- [24] L. BELL, N. DEVANATHAN et S. BOYD. « Efficient Shapley Performance Attribution for Least-Squares Regression ». In : *arXiv preprint* (2024). arXiv : [2205.06181 \[stat.ML\]](#).
- [25] Y. SHEN. « American Option Pricing using Self-Attention GRU and Shapley Value Interpretation ». In : *arXiv preprint arXiv :2310.12500* (2023).
- [26] J. CERNEVIČIENĖ et COAUTHORS. « Explainable Artificial Intelligence (XAI) in Finance : A Systematic Literature Review ». In : *Artificial Intelligence Review* (2024).
- [27] F. S. KHAN et COAUTHORS. « Model-Agnostic Explainable Artificial Intelligence Methods in Finance : A Comprehensive Review ». In : *Artificial Intelligence Review* (2025).
- [28] S. FRITZ-MORGENTHAL, T. WEYDE et al. « Financial Risk Management and Explainable, Trustworthy and Responsible AI/ML ». In : *Frontiers in Artificial Intelligence* 5 (2022), p. 779799.
- [29] CFA INSTITUTE RESEARCH AND POLICY CENTER. « Explainable AI in Finance : Addressing the Needs of Diverse Stakeholders ». In : *CFA Institute Research Report* (2025).
- [30] M. MOSCA et al. « GrammarSHAP : Explaining NLP Predictions with Sentence Structure-Aware Shapley Values ». In : *Proceedings of the 29th International Conference on Computational Linguistics* (2022), p. 4657-4669.
- [31] BASEL COMMITTEE ON BANKING SUPERVISION. *Minimum Capital Requirements for Market Risk (Basel Framework, MAR32)*. Revised 2021. 2019.
- [32] P. DJAGBA et C. NDIZIHIWE. « Pricing American Options using Machine Learning Algorithms ». In : *arXiv preprint arXiv :2409.03204* (2024).